

Sistema Híbrido de Recomendação de Cursos para Desenvolvimento Profissional


Uma solução inteligente para conectar pessoas às oportunidades certas de capacitação.


Allana Rayssa Vieira de Oliveira

Erika Cristina Alves Benesi Gomes

Nicole Fernandes Moreira

Tawany Nascimento Santos





O PROBLEMA

Informação em excesso, orientação insuficiente

A **Escola Virtual de Governo (EV.G)** oferece centenas de cursos gratuitos. Porém, a grande quantidade de opções dificulta que o usuário identifique quais capacitações são realmente relevantes para seus interesses e objetivos profissionais.

- ❏ Sem orientação personalizada, muitas oportunidades de aprendizado ficam subutilizadas.

Recomendações personalizadas com dados reais



O projeto propõe desenvolver um **sistema híbrido de recomendação** que utiliza dados públicos da EV.G para gerar sugestões de cursos alinhadas ao perfil de cada usuário.



Dados dos cursos

Características e metadados do catálogo EV.G



Histórico de interações


Padrões de matrícula e comportamento dos usuários



Perfil do usuário


Interesses, conhecimentos e objetivos profissionais

Duas bases públicas da EV.G



Catálogo de Cursos


Contém informações e características dos cursos disponíveis na plataforma — título, descrição, carga horária, área temática e demais metadados.



Histórico de Matrículas

Registra as interações entre usuários e cursos ao longo do tempo. Base de maior volume, exigindo processamento e preparação cuidadosos dos dados.

Recomendação Híbrida: duas perspectivas, um resultado



A combinação das duas abordagens compensa as limitações individuais de cada método, gerando recomendações mais robustas e personalizadas.

Content-Based Filtering

Identifica cursos similares com base nas características do conteúdo e no perfil declarado do usuário.

Collaborative Filtering

Descobre padrões de comportamento entre usuários com interesses semelhantes.

Do projeto à comunidade

01

Coleta de informações

Participantes fornecem dados padronizados sobre interesses, conhecimentos e objetivos profissionais.

03

Avaliação pelos participantes

Os usuários avaliam a relevância e utilidade das recomendações recebidas, gerando dados de validação.

02

Geração de recomendações

O sistema processa os dados e sugere cursos da EV.G alinhados ao perfil de cada participante.



Alinhado aos Objetivos de Desenvolvimento Sustentável



ODS 4 — Educação de Qualidade

Facilita a identificação e o acesso a oportunidades **gratuitas de aprendizagem**, democratizando o conhecimento.



ODS 8 — Trabalho Decente e Crescimento Econômico

Apoia o desenvolvimento de **competências profissionais** alinhadas aos objetivos de carreira dos participantes.

Etapa 1 concluída com sucesso

Tema e Bases

Definição do escopo, seleção das bases EV.G e documentação das fontes de dados.

Cronograma

Elaboração do cronograma planejado e do cronograma real para acompanhamento das atividades.

Repositório

Criação e organização do repositório GitHub com documentação inicial do projeto.

 A Etapa 1 foi revisada e ajustada conforme orientações recebidas.

Etapa 2 em andamento: Prova de Conceito



O grupo avançou na análise e preparação dos dados e implementou a **primeira prova de conceito** do componente baseado em conteúdo.

Exploração e tratamento dos dados

Análise do histórico de matrículas, inconsistências, duplicidades e valores ausentes.

Integração das bases


Cruzamento entre o histórico de matrículas e o catálogo atual de cursos da EV.G.

Primeira prova de conceito

Implementação do componente Content-Based utilizando TF-IDF e similaridade de cosseno.

Dos dados à prova de conceito

Antes de construir o sistema híbrido completo, começamos testando se os dados disponíveis permitem gerar recomendações coerentes.



Mais de 8 milhões de matrículas no recorte analisado

Histórico analisado: janeiro de 2025 a setembro de 2026

8,2M

Registros Válidos de matrículas

3,1M

Usuários distintos

1.078

Cursos identificados no histórico

7,7M

Relações Usuário-Curso

📄 O histórico de matrículas possui aproximadamente **3,11 GB**.



Primeiro, foi preciso preparar os dados

Três decisões críticas de tratamento foram tomadas antes da modelagem. Os dados brutos foram preservados — todo o tratamento foi realizado em uma cópia.

1

Registro Incompleto

A última linha do arquivo estava truncada e foi removida da cópia tratada.

2

Duplicidades

Foram identificados **38 códigos de matrícula duplicados**. Cada registro foi analisado e preservado quando representava relações distintas.

3

Valores Ausentes

Variáveis com alta ausência foram identificadas e avaliadas antes da modelagem. *Limpar não significa só excluir.*

Ferramentas utilizadas na prova de conceito

Python foi utilizado para processamento, análise e construção do primeiro modelo de recomendação.

1

Pandas + NumPy

Manipulação, tratamento e análise dos dados.

2

DuckDB

Consulta e processamento eficiente da base de matrículas de grande volume.

3

Scikit-learn


TF-IDF e cálculo da similaridade de cosseno entre os cursos.

4

Google Colab

Ambiente utilizado para desenvolvimento e execução da prova de conceito.

Bibliotecas auxiliares: os, re, unicodedata e difflib




A Matriz Usuário–Curso Revelou um Desafio

99,77%

de esparsidade

Apenas **0,2291%** das possíveis relações usuário–curso foram observadas. A grande maioria das combinações possíveis nunca ocorreu na base — o que torna a matriz extremamente esparsa e essa alta esparsidade será considerada no desenvolvimento e na avaliação do componente colaborativo.

Poucas Interações por Usuário



O que os números revelam


A **mediana** é de apenas **1 curso por usuário**, indicando que a maioria dos usuários possui histórico muito limitado.

- **59,2%** dos usuários fizeram apenas 1 curso
- **76,21%** fizeram no máximo 2 cursos



Conclusão: No recorte analisado, grande parte dos usuários apresenta poucas interações observadas.

Os dados reforçam a escolha da abordagem híbrida



Content-Based Filtering ✓

Utiliza as características textuais dos cursos para identificar conteúdos semelhantes, mesmo quando há pouco histórico de interação do usuário.

Collaborative Filtering → Próxima etapa

Utilizará o comportamento dos usuários para identificar padrões de interação e complementar as recomendações baseadas em conteúdo.



Sistema Híbrido


Conteúdo + comportamento

A combinação busca reduzir as limitações observadas em uma base com alta esparsidade e usuários com pouco histórico.

Primeira Prova de Conceito: recomendação por conteúdo

As informações textuais dos cursos foram combinadas e transformadas em vetores utilizando **TF-IDF**.

A similaridade entre os cursos é calculada pela **similaridade de cosseno**.



O modelo já consegue identificar cursos relacionados

Os cinco cursos mais similares, ordenados por similaridade de cosseno:

#	Curso Recomendado	Similaridade
1º	Excel Intermediário	0,466
2º	Excel Avançado	0,356
3º	Análise de Dados com Excel	0,310
4º	Governança de Dados	0,296
5º	Eixo 1 – Analisando Dados e Evidências	0,280



Os primeiros resultados mostram coerência temática, mas ainda não representam a avaliação final do sistema.

A prova de conceito é apenas o primeiro component

✓ Já Implementado nessa etapa:

- Tratamento e exploração dos dados
- Preparação textual do catálogo
- Vetorização com TF-IDF
- Similaridade de cosseno
- Recomendação Content-Based inicial

→ Próxima Etapa

- Desenvolver o componente colaborativo
- Combinar conteúdo + comportamento
- Definir pesos/estratégia da abordagem híbrida
- Realizar avaliação offline
- Aplicar e avaliar as recomendações com a comunidade

📌 A implementação atual indica a viabilidade inicial do componente baseado em conteúdo; o sistema híbrido completo ainda será desenvolvido.

Como o sistema será avaliado?

Está prevista uma separação temporal entre dados de treinamento e teste para avaliação rigorosa do sistema.



Precision@K

Relevância entre os primeiros resultados recomendados.



Recall@K

Capacidade de recuperar itens relevantes do catálogo.



NDCG@K

Considera a relevância e a posição dos itens recomendados.



Cobertura

Avalia o alcance do catálogo nas recomendações geradas.



Diversidade

Avalia a variedade dos itens recomendados para cada usuário.



Avaliação com a comunidade

Coleta de interesses e objetivos profissionais
Geração das recomendações
Questionário estruturado
Percepção de relevância e utilidade

📋 A avaliação combinará métricas técnicas e a percepção dos participantes.

Referencial teórico

O desenvolvimento será fundamentado em conceitos consolidados de sistemas de recomendação.

1

Sistemas de recomendação

Fundamentos e principais abordagens.

2

Content-Based Filtering

Recomendação a partir das características dos itens.

3

Collaborative Filtering


Uso das interações e padrões de comportamento dos usuários.

4

Sistemas híbridos

Combinação de diferentes estratégias de recomendação.

¹**Referências de base:** Aggarwal (2016); Ricci, Rokach e Shapira (2022); Burke (2002); Sarwar et al. (2001); Hu, Koren e Volinsky (2008).



PRÓXIMOS PASSOS

O que esperamos validar neste acompanhamento

1

Preparação dos dados

Validar as decisões de tratamento, integração e seleção das informações.

2

Estratégia híbrida

Confirmar a combinação planejada entre Content-Based e Collaborative Filtering.

3

Prova de conceito

Receber orientação sobre a abordagem inicial com TF-IDF e similaridade de cosseno.

4

Próxima entrega 02/10/2026

Alinhar a avaliação, o componente colaborativo e a evolução do projeto até a próxima entrega.