Especificação técnica consolidada — Recomendador de cursos da EV.G

Projeto Aplicado III · Versão 3 (rascunho para revisão) · 05/11/2026

Este documento reúne as decisões do grupo e a proposta técnica para o recomendador. Ele **não contém código**: descreve o que cada parte deve fazer, para revisarmos a lógica antes da implementação. Esta versão incorpora a especificação funcional do questionário (Tawany e Allana). O que ainda depende da análise da Erika está marcado como **[aguarda]**.

1. Decisões já tomadas pelo grupo

- **D1.** O perfil vem **somente do questionário**. Não se pergunta quais cursos a pessoa já fez e não há consulta ao histórico individual. O histórico real de matrículas da EV.G não é consultado: todo participante é tratado como sem histórico real. As respostas formam o perfil da sessão, que vale só para aquela sessão e não é lido pelo recomendador em usos seguintes. A palavra “histórico” fica reservada às matrículas reais, que não são usadas.
- **D2.** As respostas **não viram matrículas fictícias** e não alteram a base, o treinamento nem as tabelas de similaridade. Não há aprendizado contínuo.
- **D3.** O **modelo híbrido existente** (Content-Based + Collaborative Filtering, $\alpha = 0{,}55$, normalização do notebook) é preservado sem alterações. A estratégia baseada em perfil é uma **camada complementar**, sempre identificada como tal.
- **D4.** A recomendação pode sugerir cursos **fora da área** de atuação ou formação da pessoa.
- **D5.** Cursos de **público restrito não são escondidos**. Mostram o público-alvo e os requisitos e orientam a conferir as condições oficiais na EV.G. O sistema não decide elegibilidade. Na especificação do questionário (7.1 e regra 10), “respeitar as condições de elegibilidade” significa mostrar esse aviso, sem ocultar o curso (ver seção 15).
- **D6.** Resultados iniciais em **português**. A pessoa pode ampliar para inglês e espanhol.
- **D7.** Pesos e limiares são **parâmetros de projeto**, provisórios, definidos por testes com perfis fictícios.
- **D8.** Nenhuma seção é **preenchida artificialmente**. Sem evidência suficiente, a seção não aparece.
- **D9.** Arquivos da aplicação e registros de respostas/avaliações ficam **separados**.
- **D10.** A lista traz **até 10 cursos distintos** (especificação do questionário, seção 7).

- **D11.** O questionário só pede por digitação o nome de preferência. Todo o resto é por opções clicáveis. As opções de “não informar” e de “ainda não sei” mantêm significados distintos e nunca impedem a recomendação.

2. Visão geral do fluxo

1. A pessoa responde o questionário (adaptativo).
2. As respostas viram um **perfil** com cinco dimensões.
3. A **matriz de classificação** transforma cada dimensão em **afinidades** (uma nota de 0 a 1 para cada um dos 1.030 cursos).
4. Os cursos de maior afinidade viram **cursos de referência** (pontos de partida para consultar o modelo; não são matrículas).
5. O **modelo híbrido** é consultado a partir das referências.
6. As **regras da ponte** identificam cursos que conectam trajetória e interesses.
7. Cada curso recebe um **papel** (aprofundar, conectar ou explorar) e entra em uma das três **seções**.
8. A tela mostra os cursos e **por que** cada um foi recomendado.
9. Respostas e avaliações são gravadas à parte.

O que existe, o que se aproveita e o que é novo

Peça	Situação
Notebook, fórmula híbrida, peso do conteúdo (α) = 0,55	Existe. Preservado.
`preparar_arquivos_do_modelo.py` (cria as tabelas de semelhança)	Existe. Já inclui a popularidade dos cursos (seção 4).
Matriz de classificação (15 áreas, assuntos, público, ID canônico)	Existe. Passa a ser a ponte entre perfil e cursos.
Especificação funcional do questionário (P01 a P10)	Concluída (Tawany e Allana). Incorporada na seção 3.
Tabela de relações entre áreas	Em análise (Erika). **[aguarda]**
Perfil, afinidades, ponte, papéis, seções, explicações, registro	**Novo** (estratégia complementar).

3. Estrutura do perfil

3.1 Campos

Campo	Origem	Conteúdo	Observação
`situacao`	P01 (A a G); P03 só para quem escolheu E	Resposta de P01 e, na transição de carreira, se está trabalhando	**Só contexto.** Orienta o fluxo. Não define experiência nem formação.
`experiencia`	P02	Áreas de atuação atual + estado (3.2)	Só áreas: a P02 não tem assuntos e só pergunta a atuação atual. Preenchida **apenas** pela P02.
`formacao`	P04	Áreas de estudo, atuais e anteriores + estado	Só áreas. Distinta da experiência. A P04 aparece para todos.
`objetivo`	P06 (A a I)	Código escolhido	Orienta a composição das seções (8.4). H e I são respostas válidas e distintas.
`interesses`	P05	Áreas, assuntos e marcadores	Marcadores: `ainda_nao_sei`, `explorar_novos_temas`, `nao_informa`.
`nome_preferencia`	Campo digitado (o único)	Texto curto, opcional	Usado só para chamar a pessoa pelo nome na tela. Não é gravado nas planilhas.
`exibicao`	Tela de resultados	`incluir_outros_idiomas` (padrão: não)	Independente das respostas do questionário.
`id_participante`	Gerado pelo sistema	Código aleatório + data e hora	Sem CPF ou e-mail. É a única identificação gravada: liga as respostas, a lista e as avaliações de cada pessoa.

As áreas são sempre as **15 grandes áreas** da matriz. Os grupos temáticos (5) servem só à interface. Selecionar um grupo **não** marca suas áreas automaticamente.

3.2 Status de cada dimensão (experiência, formação, interesses)

- `informada`: há pelo menos uma área selecionada.
- `sem_opcao_adequada`: marcou “Minha profissão ou atividade não está entre as opções” (P02). Trabalha, mas a atividade não está na lista de áreas.
- `nao_informa`: marcou “Prefiro não informar” naquela pergunta (P02, P03 ou P05).
- `sem_trabalho_atual`: em transição de carreira, respondeu que não está trabalhando (P03 = B).
- `sem_selecao`: avançou a P04 sem marcar nada (a P04 não tem opção especial).
- `sem_definicao`: marcou “Ainda não sei quais temas escolher” (P05).
- `nao_perguntada`: o fluxo não exibiu a pergunta.
- Os registros guardam o estado exato: nenhum deles vira “sem experiência” ou uma área genérica. Para o cálculo, todos os estados, exceto `informada`, valem como “dimensão sem áreas”.

3.3 Respostas especiais

Resposta	Efeito no perfil
P01 = A ou D	Mostra a P02. A experiência vem da P02. Quem estuda e trabalha escolhe A e responde também a P04.
P01 = B, C, F ou G	Pula a P02: experiência `nao_perguntada`, o que **não** significa “sem experiência”. A formação (P04) vale normalmente, inclusive para quem procura o primeiro emprego.
P01 = E	Mostra a P03. P03 = A (trabalhando): mostra a P02. P03 = B: experiência `sem_trabalho_atual`. P03 = C: experiência `nao_informa`.
P02: “Minha profissão ou atividade não está entre as opções”	Opção exclusiva. Experiência `sem_opcao_adequada`.
“Prefiro não informar” (P02, P03 ou P05)	Esvazia **só aquela dimensão**. As demais permanecem.
P04 sem seleção	Formação `sem_selecao`. Segue para a P05.

Resposta	Efeito no perfil
P05: “Ainda não sei quais temas escolher”	Opção exclusiva. Interesses `sem_definicao`. A recomendação usa a base e o objetivo.
P05: “Quero explorar novos temas”	Pode ser marcada sozinha ou com áreas e assuntos. Liga `explorar_novos_temas`.
P05: “Prefiro não informar meus interesses”	Opção exclusiva. Interesses `nao_informa`.
P05: “Quero explorar” junto com “Ainda não sei”	**Decidido.** Não podem ser marcadas juntas: “Ainda não sei” é exclusiva, e “Quero explorar” só combina com áreas e assuntos.
P06 = H ou I	Respostas válidas. Usam a mesma composição equilibrada, mas são **registradas como respostas diferentes**.

3.4 Quais seções são possíveis

Para quem escolheu B, C, F ou G na P01, a base é só a formação (P04), porque a P02 não é exibida.

Dimensões com áreas	Seções possíveis
Base (experiência e/ou formação) **e** interesses	Aprofundar, conectar e explorar
Só base	Aprofundar (e explorar, se `explorar_novos_temas`)
Só interesses	Explorar
Nada	**[a confirmar]** Lista de “cursos mais procurados”, sem seções (exceção às três seções)

4. Arquivos do modelo e dados usados pelo aplicativo

Todos são **somente leitura** durante o uso.

Arquivo	Conteúdo	Origem
`ids_dos_cursos.npy`	IDs canônicos dos cursos, na ordem das tabelas	`preparar_arquivos_do_modelo.py` (existe)
`semelhanca_por_conteudo.npy`	Tabela 1.030 × 1.030: quanto cada curso se parece com os outros pelo conteúdo (Content-Based)	existe
`semelhanca_por_matriculas.npy`	Tabela 1.030 × 1.030: quanto cada curso se liga aos outros pelas matrículas históricas (Collaborative Filtering)	existe
`informacoes_do_modelo.json`	Peso do conteúdo (α), data de corte do treino e contagens	existe
`popularidade_dos_cursos.npy`	Nº de pessoas diferentes matriculadas em cada curso (também indica quais cursos têm histórico de matrículas)	existe (já incluído no script)
`matriz_cursos_resumida.csv`	Colunas essenciais da matriz (ver 5.1), na mesma ordem dos IDs	**novo**, gerado a partir da planilha

Arquivo	Conteúdo	Origem
`relacoes_entre_areas.csv`	Relações entre áreas confirmadas à mão	**[aguarda]** Erika. Vazio = evidência E5 desligada
`ajustes_da_recomendacao.json`	Todos os valores que podemos ajustar (seção 13) e a versão	novo
`textos_das_explicacoes.json`	Modelos de frase das explicações	novo
`regras_por_objetivo.json`	Ordem e prioridade das seções por objetivo	novo

Conferência obrigatória na inicialização: a lista de IDs de `matriz_cursos_resumida.csv` deve ser idêntica à de `ids_dos_cursos.npy` (mesmos 1.030 IDs, mesma ordem). Se não for, o aplicativo não inicia.

5. Representação das afinidades

5.1 Colunas da matriz usadas

`ID canônico`, `Nome do curso`, `Área principal`, `Áreas complementares`, `Assuntos (até 3)`, `Público-alvo (texto original)`, `Tipo de oferta`, `Vínculo exigido`, `Idioma`, `Carga horária (h)`, `Link do curso na EV.G`, mais os campos de texto usados na evidência E4 (competências, evidência textual). As colunas de "candidatas" da classificação automática **não** são usadas.

5.2 Cálculo

Para cada dimensão (experiência, formação, interesses) cria-se uma lista de 1.030 notas, na ordem de `ids_dos_cursos.npy`:

1. **Nota por área:** 1,0 se a área principal do curso foi escolhida; `nota_area_complementar` (inicial 0,4) se foi escolhida uma área complementar; 0 caso contrário.

2. **Várias áreas escolhidas:** vale a **maior** nota, e não a soma. Escolher muitas áreas não infla a nota.
3. **Assunto** (só nos interesses, pois a P02 e a P04 coletam apenas áreas): se algum assunto escolhido consta nos até 3 assuntos do curso, soma-se `bonus_assunto` (inicial 0,3). A comparação ignora acentos e maiúsculas. O assunto refina, não filtra.
4. A nota final é limitada a 1,0.

Resultado: `afinidade_experiencia`, `afinidade_formacao`, `afinidade_interesses`. Para a base: `afinidade_base = máximo(peso_experiencia × afinidade_experiencia, peso_formacao × afinidade_formacao)` (pesos iniciais 1 e 1). As duas notas originais são mantidas para as explicações.

Por que assim: cerca de 91% dos cursos têm duas ou mais áreas. Se a complementar valesse tanto quanto a principal, quase todo curso teria afinidade com tudo. E há mais de 1.200 assuntos diferentes, então a correspondência exata é rara: serve de reforço.

5.3 Cursos de referência

Para a base e para os interesses, escolhem-se os cursos de maior afinidade (até `qtd_cursos_referencia`, inicial 12; afinidade mínima `afinidade_minima_referencia`, inicial 0,3). Para que uma série grande não domine, cursos quase idênticos entre si (semelhança de conteúdo acima de `limite_cursos_quase_iguais`) contam uma vez. Os pesos das referências são suas afinidades.

Resultado: `referencias_base` e `referencias_interesses` (listas de cursos com pesos). **São pontos de partida de consulta, nunca matrículas.**

6. Uso das similaridades existentes

Para um conjunto de cursos de referência com seus pesos (`pesos`):

1. `nota_conteudo = pesos × semelhanca_por_conteudo` e `nota_matriculas = pesos × semelhanca_por_matriculas`.
2. Cada uma é dividida pelo seu maior valor (se o maior for 0, o resultado é 0), como na seção 6.1 do notebook.
3. `nota_hibrida = peso_conteudo × nota_conteudo + (1 − peso_conteudo) × nota_matriculas` (já divididas pelo maior valor), com **peso_conteudo = 0,55**, o α do notebook, lido de `informacoes_do_modelo.json`.

A consulta é feita duas vezes: com `referencias_base` (resultado `modelo_base`) e com `referencias_interesses` (resultado `modelo_interesses`). Guardam-se, **para cada curso**, as duas notas separadas (conteúdo e matrículas) e a nota híbrida.

Ajustes em relação ao notebook:

- A diagonal do Content-Based (curso parecido consigo mesmo) é zerada no app, porque as referências **podem** ser recomendadas. A afinidade da matriz já cuida dos acertos diretos.
- Cursos sem histórico no colaborativo (`popularidade = 0`) contam apenas pelo conteúdo, e a explicação não cita o colaborativo para eles.

Honestidade metodológica: as métricas do notebook (Recall, Hit Rate, NDCG) valem para o modelo original aplicado a históricos reais. **Não valem** para esta camada. No relatório e na tela ela se chama "recomendação baseada em perfil, com apoio do modelo híbrido".

7. Regras da ponte

A ponte só é avaliada quando há **base** (experiência e/ou formação) **e** interesses. Áreas que aparecem dos dois lados não geram ponte (nesse caso o curso é "aprofundar").

7.1 Evidências

Código	Evidência (nome no código)	Regra
E1	Estrutural, na matriz (`evidencia_area`)	**Forte:** uma área da base e uma área dos interesses entre as áreas do curso, com a **principal** em pelo menos uma delas. **Fraca:** as duas só como complementares.
E2	Assuntos em comum (`evidencia_assunto`)	O curso tem um assunto escolhido nos interesses (P05) **e** pertence, como principal ou complementar, a uma área da base. A base só tem áreas, então o assunto vem do lado dos interesses.
E3	Modelo (`evidencia_modelo`)	`ponte_pelo_modelo = mínimo(modelo_base, modelo_interesses)` , cada um normalizado de 0 a 1. Presente se `ponte_pelo_modelo ≥ limite_ponte_pelo_modelo` e cada lado ≥ `minimo_por_lado` . O mínimo exige estar **perto dos dois lados**.

Código	Evidência (nome no código)	Regra
E4	Texto (`evidencia_texto`)	O nome, as competências ou a descrição do curso trazem termos dos dois lados (termos extraídos dos nomes das áreas e assuntos escolhidos, sem palavras comuns). **Evidência de apoio:** nunca basta sozinha.
E5	Relação entre áreas (`evidencia_relacao`)	O curso tem uma área ligada, por uma relação **confirmada** em `relacoes_entre_areas.csv` , a uma área da base e a uma dos interesses. **[aguarda]** Erika. Desligada enquanto o arquivo estiver vazio.

7.2 Aprovação

O curso é **ponte aprovada** se:

- tem **E1 forte**; ou
- tem **E3** e pelo menos mais uma entre E1 fraca, E2, E4 e E5; ou
- tem pelo menos duas entre E1 fraca, E2 e E5.

Com isso, a ponte nunca depende só da afinidade nos dois blocos e nunca nasce de uma única evidência fraca.

7.3 Nota da ponte

`nota_ponte = peso_ponte_modelo × ponte_pelo_modelo + peso_ponte_evidencias × forca_das_evidencias` , em que `forca_das_evidencias` é a quantidade de evidências aprovadas (E1 forte conta 2), normalizada de 0 a 1. Valores iniciais: 0,5 e 0,5. A regra de aprovação e os limites serão calibrados nos testes (seção 14).

Exemplo (a revisar nos testes): pessoa de contabilidade que quer aprender programação. Um curso de análise de dados pode não ter as duas áreas na matriz (sem E1), mas ser próximo de cursos das duas referências (E3) e ter termos dos dois lados na descrição (E4). Nesse caso, E3 + E4 o aprova.

8. Papéis, seções e composição da lista

8.1 Definição dos papéis

Cada curso recebe **um único papel**, nesta ordem de prioridade:

1. **Conectar:** a ponte foi aprovada.
2. **Aprofundar:** há base e `afinidade_base ≥ minimo_para_aprofundar`, e a nota de aprofundar é maior ou igual à de explorar.
3. **Explorar:** `afinidade_interesses ≥ minimo_para_explorar`.

Notas:

- `nota_aprofundar = peso_afinidade_aprofundar × afinidade_base + peso_modelo_aprofundar × modelo_base` (valores iniciais 0,5 e 0,5)
- `nota_conectar = nota_ponte`
- `nota_explorar = peso_afinidade_explorar × afinidade_interesses + peso_modelo_explorar × modelo_interesses` (valores iniciais 0,5 e 0,5)

Cada curso aparece **uma só vez** na lista inteira.

8.2 As três seções

Seção	Conteúdo
Para aprofundar	Cursos relacionados à trajetória e aos conhecimentos anteriores
Para conectar conhecimentos	Cursos que estabelecem relações entre a trajetória e os novos interesses
Para explorar	Cursos relacionados aos interesses e a novas áreas

“Explorar novos temas”: se o marcador estiver ligado, `vagas_novos_temas` vagas (inicial 2) da seção Explorar são reservadas a cursos de **áreas fora do perfil**, escolhidos pela popularidade, no máximo um por área. A explicação diz que são sugestões fora das áreas indicadas. Esses cursos não repetem nenhum curso já listado nas outras seções.

8.3 Regras de exibição

- Uma seção só aparece se tiver pelo menos `minimo_cursos_secao` cursos com evidência suficiente (inicial 1). Nunca se completa com cursos fracos.
- O número de cursos de cada seção é `mínimo(candidatos elegíveis, vagas da seção)`.
- Se há base e interesses mas **nenhuma ponte aprovada**, a tela informa: “Não encontramos cursos que conectem [área da trajetória] e [interesse]”.
- Seções sem candidatos não geram mensagem, a menos que a mensagem seja pertinente (caso da ponte).

8.4 Ordem das seções e vagas por objetivo (provisório)

O objetivo define a **ordem** das seções e a **prioridade** de vagas (alta, média, baixa). Os números ficam em `regras_por_objetivo.json`.

Objetivo (P06)	Ordem das seções	Prioridade de vagas
A. Conseguir meu primeiro emprego	Aprofundar (formação), explorar, conectar	Média, média, baixa
B. Buscar uma nova oportunidade profissional	Aprofundar, conectar, explorar	Alta, média, baixa
C. Crescer ou me desenvolver na minha área atual	Aprofundar, conectar, explorar	Alta, média, baixa
D. Mudar de área ou profissão	Explorar, conectar, aprofundar	Alta, alta, baixa
E. Desenvolver conhecimentos para minhas atividades profissionais	Aprofundar, conectar, explorar	Média, alta, baixa
F. Aprender sobre assuntos de meu interesse	Explorar, conectar, aprofundar	Alta, média, baixa
G. Explorar novas possibilidades de aprendizagem	Explorar, conectar, aprofundar, com as vagas de novos temas (`vagas_novos_temas`) ligadas	Alta, média, baixa
H. Ainda não tenho um objetivo definido	Aprofundar, conectar, explorar	Média, média, média
I. Prefiro não informar	Igual a H (a resposta é registrada como diferente)	Média, média, média

Os valores da tabela são provisórios e serão testados. O objetivo também aparece na explicação (por exemplo: “Como você busca mudar de área, estes cursos funcionam como ponto de entrada”). A lista tem **até 10 cursos**: as vagas são divididas, como ponto de partida, na proporção alta 3 : média 2 : baixa 1 (com arredondamento), e as vagas de uma seção que não aparece passam para as demais. `total_de_cursos` = 10.

8.5 Filtros

- **Idioma:** só português por padrão. Se `incluir_outros_idiomas` estiver ligado, entram cursos em inglês e espanhol, com selo de idioma. O filtro é aplicado **antes** de preencher as seções.

- **Público restrito:** os cursos permanecem, com a observação sobre elegibilidade (seção 10). São os 19 marcados como “Curso Exclusivo” na coluna Tipo de oferta da matriz.
- **Quase-duplicados:** entre dois cursos da lista com semelhança de conteúdo acima de `limite_cursos_quase_iguais` (inicial 0,80), fica o de maior nota.
- **Carga horária ausente:** o curso é mantido e mostra “não informada”.

9. Critérios de ordenação

1. As **seções** seguem a ordem do objetivo (8.4).
2. Dentro de cada seção, ordena-se pela **nota da seção**: `nota_aprofundar`, `nota_conectar` ou `nota_explorar`. Notas de seções diferentes não são comparadas.
3. **Desempate:** (a) mais evidências aprovadas, (b) maior popularidade, (c) menor ID canônico (para o resultado ser sempre o mesmo).

10. Explicações e evidências exibidas

Regra de fidelidade: a explicação só usa evidências que **realmente pesaram** na nota do curso. O programa guarda as contribuições de cada curso e gera o texto a partir delas. Nunca se escreve um motivo genérico.

Para cada curso, exibe-se:

1. **Origem:** "Matriz", "Modelo" ou "Matriz + modelo".
2. **Evidência da matriz:** "Área principal: X, que você indicou em [experiência / formação / interesses]" ou "Assunto em comum: Y".
3. **Ponte** (só em "conectar"): as evidências aprovadas, em linguagem simples: combina áreas dos dois lados (E1); assuntos em comum (E2); tema próximo de cursos das duas áreas (E3); a descrição menciona termos dos dois lados (E4); relação entre áreas confirmada pelo projeto (E5).
4. **Modelo, conteúdo:** "Conteúdo semelhante ao de cursos de [área]", se a componente contribuiu acima de um limiar.
5. **Modelo, colaborativo:** "Nos dados históricos agregados de matrículas da EV.G, este curso se associa a cursos de [área]. É uma análise agregada entre cursos, sem uso de dados individuais." Só aparece se o curso tem histórico e a componente contribuiu. **Não se usam frases como "pessoas que fazem X costumam fazer Y".**
6. **Avisos:** público-alvo (texto original), vínculo exigido quando preenchido, tipo de oferta, a orientação "Confira as condições oficiais de inscrição na EV.G", idioma (se não for português), carga horária e link do curso.

Observação para cursos de acesso restrito (os marcados como “Curso Exclusivo” na matriz): “Este curso pode ter requisitos de acesso. Consulte a EV.G para confirmar se você pode se matricular.” A observação aparece na própria linha do curso, junto do público-alvo e do vínculo exigido que constam na matriz. Quem decide se a pessoa é elegível é a EV.G, no momento da inscrição. O texto exato fica em `textos_das_explicacoes.json`.

Os modelos de frase ficam em `textos_das_explicacoes.json`, para ajustarmos o texto sem mexer na lógica.

11. Organização no Google Drive

A pasta fica no Drive da Allana, compartilhada depois com o grupo.

EVG_Recomendador/

- **01_aplicacao/** (o aplicativo só **lê**)
  - `arquivos_do_modelo/`: ids, tabelas de semelhança, popularidade e informações do modelo
  - `matriz/`: a matriz resumida e `relacoes_entre_areas.csv`
  - `configuracoes/`: ajustes, textos, regras por objetivo e especificação do questionário
- **02_registros/** (o aplicativo só **escreve**)
  - planilha de **respostas** (uma linha por participante)
  - planilha de **avaliações** (P07 a P09 por lista; P10 por curso avaliado), e uma terceira planilha com as listas apresentadas
- **03_desenvolvimento/**: notebooks, scripts, perfis de teste e resultados dos testes
- **04_documentos/**: esta especificação e os relatórios

Pontos técnicos:

- A aplicação **lê os arquivos de uma pasta local ou do repositório**, não do Drive em tempo real. O Drive é a fonte oficial e o backup compartilhado (a cópia local é sincronizada). Um app publicado na internet não acessa o Drive sem credenciais; para este projeto, os arquivos (poucos MB) acompanham a aplicação.
- A **gravação** das respostas usa uma conta de serviço do Google com acesso só à pasta `02_registros`. A chave dessa conta é um segredo: fica no armazenamento de segredos do Streamlit, **nunca** no Drive compartilhado nem no código.
- A base grande de matrículas **não** precisa estar na pasta da aplicação.

Conteúdo dos registros (alinhado às seções 8 e 9 da especificação do questionário):

- **Respostas** (uma linha por participante): `id_participante`, data e hora, versão da especificação do questionário e dos parâmetros, o código de cada resposta de P01 a P06 (incluindo as opções especiais, sem transformar ausência de informação em resposta afirmativa), os IDs de grupos, áreas e assuntos selecionados e o idioma escolhido.
- **Listas apresentadas** (uma linha por curso mostrado): `id_lista`, `id_participante`, ID do curso, seção e posição. Se a lista mudar (por exemplo, ao incluir outros idiomas), nasce um novo `id_lista`.
- **Avaliações:** P07, P08 e P09 por `id_lista`; P10 por `id_lista` e ID do curso. Resposta em branco significa “não respondeu”, nunca “não”. A falta de avaliação não indica falta de interesse, e avaliação não é matrícula.
- **Acesso:** a pasta `02_registros` é compartilhada só com as pessoas envolvidas no desenvolvimento e na manutenção.

A versão dos parâmetros em cada linha permite reproduzir depois o que cada pessoa viu. Esses registros **não** alimentam o treinamento.

12. Estrutura das funções Python

O **núcleo não depende do Streamlit**. Cada função recebe os dados de que precisa e devolve um resultado, sem alterar os arquivos do modelo. Assim dá para testar tudo sem abrir o app.

Módulo	Função	Entrada → saída
`preparar_arquivos_do_modelo.py` (existe)	`executar`	base de matrículas e catálogo → arquivos do modelo da seção 4
`preparar_matriz_resumida.py` (novo)	`gerar_matriz_resumida`	planilha da matriz → `matriz_cursos_resumida.csv`
`carregamento.py`	`carregar_arquivos_do_modelo`	pasta → objeto somente leitura (conferência de IDs incluída)
`perfil.py`	`montar_perfil`	respostas do questionário → perfil (cinco dimensões e estados)
	`secoes_possiveis`	perfil → quais seções podem existir
`afinidade.py`	`calcular_afinidades`	perfil + matriz → `afinidade_experiencia`, `afinidade_formacao`, `afinidade_interesses`, `afinidade_base`

Módulo	Função	Entrada → saída
	`escolher_referencias`	afinidade → referências com pesos
`modelo_hibrido.py`	`calcular_notas_do_modelo`	referências + tabelas de semelhança + peso do conteúdo → nota de conteúdo, nota de matrículas e nota híbrida por curso
`ponte.py`	`avaliar_ponte`	perfil, afinidades, notas do modelo, matriz, relações → por curso: evidências, aprovação, nota
`composicao.py`	`atribuir_papeis`	notas → papel de cada curso
	`filtrar_cursos`	idioma e opção de ampliar
	`montar_secoes`	papéis, objetivo, ajustes → seções, vagas e ordem
	`remover_quase_duplicados`	lista + semelhança → lista sem repetições
`explicacao.py`	`montar_explicacao`	curso + contribuições + textos → explicação estruturada
`recomendar.py`	`recomendar`	respostas + arquivos do modelo + ajustes → resultado completo (seções, notas, evidências, avisos)
`registro.py`	`salvar_resposta`, `salvar_avaliacao`	resultado/avaliação → planilhas de `02_registros` (falha de gravação não derruba o aplicativo)
`aplicativo.py`	telas do Streamlit	usa `recomendar`; guarda o estado de cada pessoa em `st.session_state` (nome definido pelo próprio Streamlit)

Módulo adicional `questionario.py` (novo): `proxima_pergunta(pergunta_atual, respostas)` devolve a próxima pergunta conforme a tabela de navegação da especificação do questionário. `aplicar_exclusividades(pergunta, marcadas)` desmarca e desabilita as demais opções quando uma opção exclusiva é escolhida. `validar_resposta(pergunta, resposta)` aceita avançar sem seleção na P04 e as respostas H e I da P06.

Sessões independentes: o Streamlit mantém separado o estado de cada visitante. Os arquivos do modelo são carregados uma vez e **marcados como somente leitura**. As funções criam suas próprias cópias de trabalho, então nenhuma sessão altera os dados da outra.

13. Parâmetros provisórios

Todos em `ajustes_da_recomendacao.json`, com número de versão. **São valores de partida para os testes, não decisões.**

Ajuste	Valor inicial	Função
`peso_conteudo`	0,55	Peso do Content-Based na nota híbrida (fixo, o α do notebook)
`nota_area_complementar`	0,4	Nota de área complementar
`bonus_assunto`	0,3	Bônus de assunto (só nos interesses)
`peso_experiencia`, `peso_formacao`	1 e 1	Peso de experiência e formação na base
`qtd_cursos_referencia`, `afinidade_minima_referencia`	12 e 0,3	Quantidade e afinidade mínima das referências
`limite_cursos_quase_iguais`	0,80	Limite para considerar cursos quase iguais
`limite_ponte_pelo_modelo`, `minimo_por_lado`	a calibrar	Limites da evidência E3
`peso_ponte_modelo`, `peso_ponte_evidencias`	0,5 e 0,5	Composição da nota da ponte
`peso_afinidade_aprofundar`, `peso_modelo_aprofundar`, `peso_afinidade_explorar`, `peso_modelo_explorar`	0,5 cada	Composição das notas de aprofundar e explorar
`minimo_para_aprofundar`, `minimo_para_explorar`	a calibrar	Evidência mínima para entrar em cada seção
`minimo_cursos_secao`	1	Mínimo de cursos para exibir uma seção

Ajuste	Valor inicial	Função
`total_de_cursos`, `vagas_novos_temas`	10 e 2	Tamanho da lista e vagas de “novos temas”

14. Testes necessários

14.1 Testes automáticos

- **Arquivos do modelo:** formato 1.030 × 1.030, ordem dos IDs igual à da matriz, sem valores ausentes.
- **Modelo:** para um conjunto de referências, o resultado é igual à fórmula do notebook (α = 0,55). É o teste que garante que o modelo original foi preservado.
- **Perfil:** cada linha da tabela 3.3; situação não define experiência (caso de quem estuda e trabalha: escolhe A na P01 e responde P02 e P04; caso do primeiro emprego: experiência não perguntada); "prefiro não informar" não apaga outras respostas.
- **Afinidade:** principal maior que complementar; bônus de assunto; várias áreas pela maior nota; valores entre 0 e 1.
- **Ponte:** um caso construído para cada regra de aprovação; sem ponte com só um lado; sem ponte quando a área é a mesma dos dois lados.
- **Composição:** cada curso aparece uma vez; seção sem evidência não aparece; ordem das seções conforme o objetivo; português por padrão; inglês e espanhol só quando ligado; cursos restritos com aviso.
- **Explicações:** toda evidência exibida existe nas contribuições; nenhuma frase sugere dado individual.
- **Isolamento:** duas sessões seguidas com perfis diferentes não alteram os arquivos do modelo (conferência por soma de verificação antes e depois).
- **Registro:** gravação na planilha correta e separada; falha de gravação não impede mostrar os resultados.
- **Fluxo do questionário:** cada linha da tabela de navegação; a P04 aparece para todos; exclusividade das opções especiais (desmarcar e desabilitar); avançar sem selecionar na P04; H e I da P06 como respostas válidas; P02 só para A, D e E com trabalho.
- **Avaliações (P07 a P10):** opcionais, vinculadas à lista exibida; resposta em branco gravada como não respondida.

14.2 Perfis fictícios (cerca de 8)

1. Contabilidade + quer aprender programação (exemplo do projeto).

2. Estudou Administração, trabalha com Contabilidade, quer crescer.
3. Procura o primeiro emprego, só com formação (não responde a P02).
4. Estuda e também trabalha em outra área (escolhe A na P01).
5. Transição de carreira, com área anterior e área nova.
6. Só interesses (todo o resto "prefiro não informar").
7. Marcou "explorar novos temas".
8. Só base, sem interesses ("ainda não sei").

Em cada um conferimos: pontes (lendo as evidências), coerência com o objetivo, ausência de cursos claramente fora de lugar e seções corretamente ocultas.

14.3 Sensibilidade e revisão humana

Variar um parâmetro de cada vez e registrar o efeito. O grupo revisa as listas e as pontes dos perfis fictícios. Os parâmetros só são fixados depois dessa revisão.

15. Pontos em aberto e como entram as atualizações

Já decidido e aplicado nesta especificação e no documento do questionário:

- O perfil criado pelas respostas vale só para a sessão. O histórico real de matrículas não é consultado, e a palavra “histórico” fica reservada a ele.
- O nome de preferência não é gravado. Cada participante tem um ID único.
- “Ainda não sei” e “Prefiro não informar meus interesses” não combinam com “Quero explorar novos temas”.
- Cursos de acesso restrito são recomendados com a observação para conferir a elegibilidade na EV.G.
- A opção B da P01 passa a ser “Estou apenas estudando”. Quem estuda e trabalha escolhe A, e a experiência significa só a atuação atual.

Ainda em aberto:

Ponto	Responsável	Efeito
Tabela de relações entre áreas	Erika	Preenche `relacoes_entre_areas.csv` e liga a evidência E5. Define o formato exato (sugestão: área A, área B, tipo de relação, confirmada sim/não, observação).

Ponto	Responsável	Efeito
Associação de assuntos às áreas	Tawany	Conferir, na matriz, a associação dos assuntos às áreas (item da seção 11 do questionário).
Lista de “mais procurados” quando o perfil está vazio	Grupo	Confirmar se é a saída adequada.
Aviso sobre cursos já feitos	Grupo	Sem consulta ao histórico, o sistema não evita cursos que a pessoa já fez. Decidir se a tela de resultados traz um aviso.
Data de corte do treino do colaborativo	Allana	Hoje usa todas as matrículas até 02/09/2026. Confirmar.
Privacidade e retenção	Grupo	Definir antes de publicar (seção 9.4 do questionário): dados coletados, quem acessa, tempo de guarda, proteção e aviso de uso.
Parâmetros	Grupo	Definidos após os testes (seção 14).

Cada mudança relevante gera uma nova versão deste documento e do `ajustes_da_recomendacao.json`.

16. Glossário de nomes e formatos

Todos os nomes de arquivos, funções e ajustes estão em português, para facilitar a leitura. Esta seção explica os termos e mostra como cada nome mudou em relação às versões anteriores.

Termo	O que significa
Arquivos do modelo	Antes chamados de “artefatos”. São os arquivos prontos que o aplicativo lê. Criados uma vez, não mudam durante o uso.
`.npy`	Tabela de números salva pelo NumPy (uma biblioteca do Python). Carrega rápido.
`.json`	Arquivo de texto com valores e configurações. Dá para abrir e editar no bloco de notas.
`.csv`	Tabela simples em texto. Abre no Excel.

Termo	O que significa
Semelhança	O mesmo que “similaridade”: um número de 0 a 1 que diz o quanto dois cursos se parecem ou andam juntos.
Semelhança por conteúdo	Parecença pelo texto dos cursos (Content-Based).
Semelhança por matrículas	Parecença pelas matrículas históricas (Collaborative Filtering).
Peso do conteúdo	O α do notebook (0,55): quanto o conteúdo pesa na nota híbrida.
Curso de referência	Curso de partida usado para consultar o modelo. Não é matrícula.
Nota híbrida	Junção da nota de conteúdo com a nota de matrículas.

De onde viemos (nome antigo → nome novo):

Antes	Agora
`preparar_artefatos.py`	`preparar_arquivos_do_modelo.py`
pasta `artefatos` ou `artefatos_modelo`	`arquivos_do_modelo`
`ids_cursos.npy`	`ids_dos_cursos.npy`
`similaridade_content.npy`	`semelhanca_por_conteudo.npy`
`similaridade_cf.npy`	`semelhanca_por_matriculas.npy`
`meta.json`	`informacoes_do_modelo.json`
`popularidade.npy`	`popularidade_dos_cursos.npy`
`matriz_catalogo_leve`	`matriz_cursos_resumida.csv`
`relacoes_areas.csv`	`relacoes_entre_areas.csv`
`parametros.json`	`ajustes_da_recomendacao.json`
`textos_explicacao.json`	`textos_das_explicacoes.json`
`regras_objetivo.json`	`regras_por_objetivo.json`
`main`, `preparar_matriz.py`, `gerar_matriz_leve`	`executar`, `preparar_matriz_resumida.py`, `gerar_matriz_resumida`

Antes	Agora
`carregar_artefatos`	`carregar_arquivos_do_modelo`
`modelo.py`, `pontuar_modelo`	`modelo_hibrido.py`, `calcular_notas_do_modelo`
`app.py`	`aplicativo.py`
`alpha`	`peso_conteudo`
`p_comp`, `b_assunto`	`nota_area_complementar`, `bonus_assunto`
`peso_exp`, `peso_form`	`peso_experiencia`, `peso_formacao`
`K_ref`, `piso_ref`	`qtd_cursos_referencia`, `afinidade_minima_referencia`
`theta_dup`	`limite_cursos_quase_iguais`
`theta_modelo`, `piso_lado`	`limite_ponte_pelo_modelo`, `minimo_por_lado`
`lambda1`, `lambda2`	`peso_ponte_modelo`, `peso_ponte_evidencias`
`a1`, `a2`, `e1`, `e2`	`peso_afinidade_aprofundar`, `peso_modelo_aprofundar`, `peso_afinidade_explorar`, `peso_modelo_explorar`
`piso_apr`, `piso_exp`	`minimo_para_aprofundar`, `minimo_para_explorar`
`n_min`	`minimo_cursos_secao`
`N_total`, `n_novos`	`total_de_cursos`, `vagas_novos_temas`
`A_exp`, `A_form`, `A_int`, `A_base`	`afinidade_experiencia`, `afinidade_formacao`, `afinidade_interesses`, `afinidade_base`
`R_base`, `R_int`	`referencias_base`, `referencias_interesses`
`M_base`, `M_int`	`modelo_base`, `modelo_interesses`
`P_modelo`, `P`, `F`	`ponte_pelo_modelo`, `nota_ponte`, `forca_das_evidencias`
`S_apr`, `S_con`, `S_exp`	`nota_aprofundar`, `nota_conectar`, `nota_explorar`

Antes	Agora
`score_content`, `score_cf`	`nota_conteudo`, `nota_matriculas`

Uma exceção: `st.session_state` é um nome do próprio Streamlit e não pode ser traduzido.