SISTEMA HÍBRIDO DE RECOMENDAÇÃO DE CURSOS PARA DESENVOLVIMENTO PROFISSIONAL

ALLANA RAYSSA VIEIRA DE OLIVEIRA - 10397812
ERIKA CRISTINA ALVES BENESI GOMES - 10732522
NICOLE FERNANDES MOREIRA - 10747302
TAWANY NASCIMENTO SANTOS - 10746742

UNIVERSIDADE PRESBITERIANA MACKENZIE

São Paulo, 2026

SUMÁRIO

1 INTRODUÇÃO 3
1.1 Contexto do trabalho 3
1.2 Motivação 4
1.3 Justificativa 5
1.4 Objetivo geral, objetivos específicos da pesquisa e objetivo extensionista 5
Objetivo geral 5
Objetivos específicos 6
Objetivo extensionista 6
2 REFERENCIAL TEÓRICO 7
2.1 Sistemas de recomendação 7
2.2 Recomendação baseada em conteúdo 8
2.3 Filtragem colaborativa 9
2.4 Sistemas híbridos de recomendação 10
2.5 Sistemas de recomendação na educação 11
2.6 Avaliação de sistemas de recomendação 12
3 METODOLOGIA 15
3.1 Definição do Problema e Objetivos 16
3.2 Coleta de Dados 18
3.3 Pré-processamento e Limpeza dos Dados 18
3.4 Divisão dos Dados 20
3.5 Seleção e Implementação do Algoritmo 22
3.5.1 Recomendação baseada em conteúdo (*Content-Based Filtering*) 22
3.5.2 Filtragem colaborativa *item-based* (*Item-Based Collaborative Filtering*) 23
3.5.3 Modelo híbrido 23
3.6 Treinamento do Modelo 24
3.7 Avaliação do Desempenho 25
3.7.1 Protocolo de avaliação 25
3.7.2 Métricas 26
3.7.3 *Baseline* de popularidade 26
3.7.4 Resultados 26
3.7.5 Limitações da avaliação 27
3.8 Otimização e Ajustes 28
3.8.1 Escolha do peso α do modelo híbrido 28
3.8.2 Limitações identificadas e melhorias previstas 29
3.9 Implantação e Monitoramento 30
4 REFERÊNCIAS 32

1 INTRODUÇÃO

1.1 Contexto do trabalho

Atualmente, a qualificação profissional não acontece apenas no início da carreira. Com as mudanças no mercado de trabalho e o uso cada vez maior de tecnologia nas atividades profissionais, as pessoas precisam atualizar seus conhecimentos com frequência. Isso aumentou a procura por cursos online, que permitem estudar sem restrição de horário e de local. O Censo da Educação Superior de 2024, divulgado pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP), mostra esse crescimento: as matrículas em cursos a distância já superam as dos cursos presenciais, e a modalidade está presente em 3.387 municípios brasileiros, o equivalente a 61% do total. Além da educação formal, também cresceu a oferta de cursos livres e de curta duração, muitos deles gratuitos.

O aumento da oferta facilitou o acesso à capacitação, mas criou outra dificuldade: a de escolher o que estudar. Em catálogos com centenas ou milhares de cursos, o usuário precisa decidir sozinho qual curso fazer, em que ordem e com qual profundidade. Na maioria das plataformas, essa decisão é apoiada apenas por busca por palavra-chave, filtros por área e listas dos cursos mais acessados. Esses recursos funcionam bem quando a pessoa já sabe o nome daquilo que procura, mas ajudam pouco quem ainda não conhece as opções da área em que pretende atuar. Como consequência, a busca pode se tornar demorada e levar à escolha de conteúdos que não correspondem ao objetivo profissional ou ao nível de conhecimento que o usuário já possui.

Os sistemas de recomendação foram desenvolvidos para lidar com esse tipo de problema. Eles analisam informações sobre os itens disponíveis e sobre o comportamento dos usuários para sugerir aquilo que tem maior chance de ser relevante para cada pessoa. Já são utilizados em lojas virtuais e em serviços de *streaming* e vêm sendo aplicados também na área educacional, para indicar cursos, disciplinas e materiais de estudo. As abordagens mais comuns são a filtragem baseada em conteúdo (*content-based*), que sugere itens parecidos com aqueles pelos quais o usuário já demonstrou interesse; a filtragem colaborativa (*collaborative filtering*), que utiliza o comportamento de usuários com histórico semelhante; e a abordagem híbrida, que combina as duas para reduzir as limitações de cada uma.

No Brasil, a Escola Virtual de Governo (EV.G), mantida pela Escola Nacional de Administração Pública (ENAP), é um exemplo desse cenário. A plataforma reúne em um catálogo único mais de mil cursos gratuitos e abertos a qualquer pessoa, organizados em áreas como dados e informação, gestão de pessoas, tecnologia da informação, políticas públicas e ética e cidadania. Seu portal de dados abertos registra mais de 23 milhões de matrículas e cerca de 6,7 milhões de usuários. A quantidade de cursos disponíveis mostra que

a dificuldade de escolha também está presente nessa plataforma e o volume de matrículas registradas indica que existem dados suficientes para identificar padrões de uso e apoiar a recomendação.

Diante desse cenário, este projeto propõe o desenvolvimento de um sistema híbrido de recomendação de cursos voltado ao desenvolvimento profissional, que leve em consideração o perfil, os interesses e o histórico de interações dos usuários. Serão utilizados o catálogo de cursos e a base de matrículas da EV.G, com a finalidade de ajudar o usuário a encontrar cursos mais adequados aos seus objetivos sem depender apenas de buscas manuais.

Os materiais relacionados ao desenvolvimento do projeto, incluindo os conjuntos de dados utilizados, códigos e demais artefatos produzidos ao longo das etapas, serão organizados no repositório do projeto no GitHub, disponível em: https://github.com/Allana691/Projeto-aplicado-III

1.2 Motivação

A escolha do tema está relacionada à crescente oferta de cursos de capacitação e à necessidade de facilitar a escolha de oportunidades de desenvolvimento profissional que sejam adequadas aos diferentes perfis e objetivos dos usuários. Embora existam diversas plataformas que disponibilizam cursos gratuitos e pagos, a grande quantidade de opções pode dificultar a identificação de conteúdos realmente relevantes para cada pessoa.

Nesse contexto, o projeto busca contribuir para tornar o processo de busca por capacitação mais direcionado, considerando que diferentes usuários possuem interesses, conhecimentos prévios e objetivos profissionais distintos. A utilização de dados para apoiar esse processo pode reduzir a necessidade de buscas manuais e auxiliar o usuário na identificação de cursos potencialmente mais relevantes para sua trajetória profissional.

A escolha da Escola Virtual de Governo (EV.G) como fonte de dados também contribui para a relevância social do projeto, uma vez que a plataforma disponibiliza cursos gratuitos de diferentes áreas de conhecimento, ampliando o acesso à capacitação profissional.

1.3 Justificativa

O desenvolvimento de um sistema de recomendação de cursos para capacitação profissional é justificado pela crescente quantidade de opções disponíveis e pela dificuldade dos usuários em identificar quais conteúdos são mais adequados aos seus interesses, conhecimentos e objetivos. Embora a oferta de cursos online facilite o acesso à capacitação, a grande quantidade de alternativas pode tornar o processo de escolha mais demorado e pouco direcionado. Nesse contexto, a utilização de sistemas de recomendação pode auxiliar os usuários na identificação de cursos potencialmente mais relevantes para seu desenvolvimento profissional, reduzindo a dependência de buscas manuais e de listas gerais de conteúdos.

A utilização de uma abordagem híbrida é relevante por permitir a combinação de diferentes informações para gerar recomendações personalizadas. A recomendação baseada em conteúdo pode considerar as características dos cursos e os interesses dos usuários, enquanto a filtragem colaborativa pode utilizar o histórico de interações para identificar padrões de comportamento entre usuários com preferências semelhantes. A combinação dessas abordagens possibilita a geração de recomendações mais completas e adequadas aos diferentes perfis, além de representar uma aplicação prática de técnicas de Ciência de Dados.

A proposta também apresenta viabilidade devido à disponibilidade de dados reais e brasileiros da Escola Virtual de Governo (EV.G). As bases analisadas possuem informações suficientes sobre os cursos e um histórico significativo de matrículas, possibilitando o desenvolvimento e a avaliação do sistema com base em dados reais. Além de sua aplicação técnica, o projeto possui relevância prática e social, pois a disponibilização do sistema para testes pela comunidade permitirá avaliar a utilidade das recomendações e contribuir para o aprimoramento da solução, auxiliando pessoas na busca por oportunidades de capacitação e desenvolvimento profissional.

1.4 Objetivo geral, objetivos específicos da pesquisa e objetivo extensionista

Objetivo geral

Desenvolver um sistema híbrido de recomendação de cursos voltado ao desenvolvimento profissional, combinando características dos cursos e o histórico de interações dos usuários para gerar recomendações personalizadas de acordo com seus interesses e perfis.

Objetivos específicos

- Analisar as informações disponíveis no catálogo de cursos e no histórico de matrículas da Escola Virtual de Governo (EV.G), identificando os dados relevantes para o desenvolvimento do sistema de recomendação;
- Preparar os dados selecionados para possibilitar sua utilização nas técnicas de recomendação;
- Aplicar técnicas de recomendação baseada em conteúdo, considerando as características dos cursos e os interesses dos usuários;
- Aplicar técnicas de filtragem colaborativa, utilizando o histórico de interações para identificar padrões entre usuários e cursos;
- Combinar as abordagens baseada em conteúdo e colaborativa para desenvolver um sistema híbrido de recomendação;
- Avaliar a qualidade e a relevância das recomendações geradas pelo sistema por meio de métodos adequados de avaliação.

Objetivo extensionista

Aplicar o sistema de recomendação junto à comunidade, utilizando informações padronizadas sobre interesses, conhecimentos e objetivos profissionais dos participantes para gerar recomendações personalizadas de cursos da Escola Virtual de Governo (EV.G) e avaliar, por meio de questionário estruturado, a percepção dos usuários quanto à relevância e à utilidade das recomendações apresentadas. A aplicação busca contribuir para facilitar o acesso a oportunidades de capacitação e desenvolvimento profissional, atendendo às necessidades relacionadas ao ODS 4 – Educação de Qualidade e ao ODS 8 – Trabalho Decente e Crescimento Econômico.

A relação com o ODS 4 ocorre pela utilização de um sistema de recomendação para auxiliar os participantes na identificação de oportunidades gratuitas de aprendizagem mais adequadas aos seus interesses, conhecimentos e objetivos, contribuindo para tornar a busca por capacitação mais direcionada. Em relação ao ODS 8, o projeto busca apoiar o desenvolvimento profissional dos participantes ao recomendar cursos que contribuam para a aquisição e o aprimoramento de conhecimentos e competências relacionados aos seus objetivos profissionais.

2 REFERENCIAL TEÓRICO

Este capítulo apresenta os conceitos que fundamentam o desenvolvimento de sistemas de recomendação e sua aplicação no contexto educacional. Considerando que o projeto propõe um sistema híbrido de recomendação de cursos, são discutidas inicialmente as características gerais dos sistemas de recomendação e, em seguida, as abordagens baseada em conteúdo e colaborativa, bem como sua combinação em sistemas híbridos.

Também são apresentados estudos sobre a aplicação dessas técnicas na educação e, especificamente, na recomendação de cursos. Por fim, são discutidas formas de avaliação de sistemas de recomendação, incluindo métricas adequadas para sistemas que produzem listas ordenadas de itens. Esses conceitos fornecem a fundamentação necessária para compreender as técnicas utilizadas no desenvolvimento do projeto.

2.1 Sistemas de recomendação

Com o crescimento da quantidade de informações, produtos e serviços disponíveis em ambientes digitais, tornou-se mais difícil para os usuários localizar itens relevantes entre um grande número de alternativas. Os sistemas de recomendação surgiram como uma forma de reduzir essa sobrecarga de informação por meio da identificação de itens potencialmente relevantes para cada usuário (ADOMAVICIUS; TUZHILIN, 2005).

Ricci, Rokach e Shapira (2022) definem os sistemas de recomendação como ferramentas e técnicas de software destinadas a fornecer sugestões de itens que possam ser úteis a determinado usuário. Nesse contexto, o termo “item” pode representar diferentes elementos, como produtos, filmes, notícias, músicas ou cursos, dependendo do domínio em que o sistema é aplicado.

Segundo Adomavicius e Tuzhilin (2005), uma das funções de um sistema de recomendação consiste em estimar a utilidade de itens para usuários e, a partir dessa estimativa, selecionar aqueles considerados mais relevantes. Em determinadas aplicações, o objetivo não é prever uma avaliação numérica específica, mas produzir uma lista ordenada dos itens considerados mais adequados. Esse tipo de problema é conhecido como recomendação Top-N (AGGARWAL, 2016).

Existem diferentes abordagens para produzir recomendações. Entre elas estão os métodos baseados em conteúdo, que utilizam características dos itens; os métodos colaborativos, que exploram padrões existentes nas interações dos usuários; os métodos baseados em conhecimento; e os sistemas híbridos, que combinam duas ou mais estratégias (BURKE, 2002; RICCI; ROKACH; SHAPIRA, 2022).

Outro aspecto importante diz respeito à forma como as preferências dos usuários são obtidas. No *feedback* explícito, o usuário fornece diretamente uma avaliação sobre determinado item, por exemplo, atribuindo-lhe uma nota. No *feedback* implícito, por outro lado, as preferências são inferidas a partir de comportamentos observáveis, como compras, cliques ou outras formas de interação (HU; KOREN; VOLINSKY, 2008).

Hu, Koren e Volinsky (2008) destacam que dados implícitos apresentam características diferentes das avaliações explícitas. A ausência de uma interação não representa necessariamente falta de interesse, assim como uma interação não permite concluir diretamente o grau de satisfação do usuário. Ainda assim, esse tipo de informação possibilita explorar padrões de comportamento quando avaliações explícitas não estão disponíveis.

No contexto educacional, registros de matrícula podem constituir uma forma de interação implícita entre usuários e cursos. Essa característica é particularmente relevante para bases como a da Escola Virtual de Governo (EV.G), utilizada neste projeto, na qual o histórico disponível registra as matrículas e suas respectivas situações, mas não apresenta avaliações individuais dos cursos pelos usuários.

2.2 Recomendação baseada em conteúdo

A recomendação baseada em conteúdo (*content-based recommendation*) utiliza as características dos itens para identificar elementos semelhantes àqueles pelos quais um usuário já demonstrou interesse. Para isso, os itens precisam ser representados por seus atributos e o histórico de interação pode ser utilizado para construir um perfil de preferências do usuário (LOPS; GEMMIS; SEMERARO, 2011).

Quando os itens possuem informações textuais, esses textos precisam ser transformados em uma representação numérica para que possam ser comparados computacionalmente. Uma técnica tradicional para essa finalidade é o TF-IDF (*Term Frequency – Inverse Document Frequency*), que representa documentos por meio de vetores nos quais os termos recebem pesos de acordo com sua frequência no documento e sua ocorrência no conjunto de documentos (SALTON; BUCKLEY, 1988).

A lógica do TF-IDF permite reduzir a importância de termos muito frequentes no conjunto de documentos e atribuir maior peso àqueles mais representativos de determinado texto. Dessa forma, descrições textuais podem ser convertidas em vetores capazes de representar parte de suas características. Após a representação vetorial dos itens, medidas de similaridade podem ser utilizadas para comparar esses vetores. Entre elas está a similaridade do cosseno, que considera o ângulo formado entre dois vetores. Quanto maior a similaridade,

maior tende a ser a proximidade entre suas representações (LOPS; GEMMIS; SEMERARO, 2011).

Uma das vantagens da recomendação baseada em conteúdo é a possibilidade de recomendar itens utilizando suas próprias características, mesmo quando esses itens ainda possuem poucas ou nenhuma interação. Além disso, as características responsáveis pela recomendação podem contribuir para sua explicabilidade (LOPS; GEMMIS; SEMERARO, 2011).

Essa abordagem também apresenta limitações. A qualidade das recomendações depende das informações disponíveis para descrever os itens, e o sistema pode apresentar superespecialização, recomendando itens excessivamente semelhantes àqueles já conhecidos pelo usuário. Também existe o problema relacionado a usuários novos, para os quais ainda não há histórico suficiente para representar suas preferências (LOPS; GEMMIS; SEMERARO, 2011).

No domínio de cursos, características como título, descrição, conteúdo programático, público-alvo e área temática podem fornecer informações úteis para a representação dos itens. O catálogo da EV.G contém diferentes atributos textuais desse tipo, permitindo que os cursos sejam caracterizados a partir de seus conteúdos.

2.3 Filtragem colaborativa

A filtragem colaborativa (*collaborative filtering*) utiliza as interações registradas entre usuários e itens para identificar padrões de preferência. A ideia fundamental é que informações sobre comportamentos anteriores podem ser utilizadas para estimar quais itens poderão ser relevantes para determinado usuário (HERLOCKER et al., 2004).

Aggarwal (2016) apresenta diferentes formas de filtragem colaborativa, incluindo métodos baseados em vizinhança e métodos baseados em modelos. Nos métodos de vizinhança, a similaridade pode ser calculada entre usuários ou entre itens. Na abordagem baseada em usuários, são identificados usuários com padrões de interação semelhantes. Na abordagem baseada em itens (*item-based*), por outro lado, são identificados itens que apresentam padrões semelhantes de interação.

Sarwar et al. (2001) estudaram algoritmos de filtragem colaborativa baseados em itens, nos quais as relações entre os itens são calculadas a partir dos usuários que interagiram com eles. Essa abordagem permite utilizar as relações identificadas entre itens para produzir recomendações.

Linden, Smith e York (2003) apresentam um exemplo conhecido da aplicação dessa estratégia em grande escala na Amazon, utilizando filtragem colaborativa item a item para lidar com grandes quantidades de usuários e produtos. A abordagem baseada em itens pode

ser especialmente relevante em cenários nos quais o número de usuários é significativamente superior ao número de itens disponíveis.

Quando as interações correspondem a *feedback* implícito, a relação entre usuário e item pode ser representada, por exemplo, pela ocorrência ou não de determinada interação. A similaridade entre itens pode então ser estimada a partir dos padrões de interação observados (AGGARWAL, 2016).

Apesar de amplamente utilizada, a filtragem colaborativa apresenta limitações. Uma delas é a esparsidade, decorrente do fato de que cada usuário normalmente interage apenas com uma pequena parcela dos itens disponíveis, deixando grande parte da matriz usuário-item sem interações (ADOMAVICIUS; TUZHILIN, 2005).

Outra limitação é o problema de partida a frio (*cold-start*), que pode ocorrer quando um usuário ainda não possui histórico suficiente ou quando um item novo ainda não recebeu interações (SCHEIN et al., 2002). Esse problema também é discutido no contexto específico de sistemas de recomendação de cursos por Algarni e Sheldon (2023), que identificam o *cold-start* entre os desafios encontrados nesse domínio.

2.4 Sistemas híbridos de recomendação

Os sistemas híbridos combinam duas ou mais técnicas de recomendação com o objetivo de aproveitar características complementares e reduzir limitações associadas a abordagens individuais (BURKE, 2002).

Uma combinação recorrente envolve métodos baseados em conteúdo e filtragem colaborativa. Enquanto a abordagem baseada em conteúdo utiliza as características dos itens e pode lidar melhor com itens que ainda possuem poucas interações, a filtragem colaborativa utiliza padrões coletivos de comportamento e pode identificar relações que não seriam evidentes apenas pela análise das características dos itens (BURKE, 2002; ADOMAVICIUS; TUZHILIN, 2005).

Burke (2002) apresenta diferentes estratégias para a construção de sistemas híbridos, entre elas as formas ponderada (*weighted*), alternada (*switching*), mista (*mixed*), combinação de atributos (*feature combination*), cascata (*cascade*), aumento de atributos (*feature augmentation*) e meta-nível (*meta-level*).

Na estratégia ponderada, por exemplo, diferentes componentes podem produzir pontuações que posteriormente são combinadas por meio de pesos. Quando as pontuações são produzidas em escalas diferentes, sua combinação pode exigir procedimentos de normalização para permitir uma comparação adequada.

Çano e Morisio (2017), em uma revisão sistemática sobre sistemas híbridos de recomendação, analisam diferentes formas de hibridização e destacam a utilização recorrente

da combinação entre filtragem colaborativa e métodos baseados em conteúdo. A literatura relaciona o uso de abordagens híbridas à possibilidade de compensar limitações presentes quando cada técnica é empregada isoladamente.

No contexto específico da recomendação de cursos, Guruge, Kadel e Halder (2021) analisaram pesquisas publicadas entre 2016 e 2020 e identificaram diferentes metodologias, incluindo técnicas colaborativas, baseadas em conteúdo, baseadas em conhecimento, mineração de dados e sistemas híbridos. Os autores observaram crescimento da utilização de abordagens híbridas nas pesquisas analisadas.

A combinação entre conteúdo e comportamento apresenta relação direta com problemas como o da partida a frio. Um componente baseado em conteúdo pode utilizar as características de um curso mesmo quando ele possui poucas interações, enquanto um componente colaborativo pode explorar padrões existentes no histórico dos usuários. Essas propriedades tornam os sistemas híbridos particularmente relevantes para ambientes que possuem simultaneamente informações sobre os itens e registros de interação.

2.5 Sistemas de recomendação na educação

Na área educacional, sistemas de recomendação têm sido estudados como ferramentas para apoiar a seleção de diferentes tipos de recursos, como materiais de aprendizagem, objetos educacionais, cursos e outros conteúdos relacionados ao processo de ensino e aprendizagem.

Urdaneta-Ponte, Mendez-Zorrilla e Oleagordia-Ruiz (2021) realizaram uma revisão sistemática sobre sistemas de recomendação aplicados à educação. O estudo analisou 98 trabalhos selecionados a partir de pesquisas em bases como IEEE, ACM, Scopus e Web of Science e identificou como principais abordagens a filtragem colaborativa, a recomendação baseada em conteúdo e os sistemas híbridos. Os autores também observaram uma tendência de utilização de técnicas de aprendizado de máquina nos estudos mais recentes analisados.

Khanal et al. (2020), em uma revisão sistemática sobre sistemas de recomendação baseados em aprendizado de máquina para *e-learning*, também apresentam diferentes estratégias utilizadas nesse domínio, incluindo abordagens colaborativas, baseadas em conteúdo, híbridas e baseadas em conhecimento.

Especificamente em relação à recomendação de cursos, Guruge, Kadel e Halder (2021) destacam que a diversidade de opções pode dificultar a seleção de cursos compatíveis com os conhecimentos e objetivos dos usuários. Ao revisar metodologias empregadas em sistemas de recomendação de cursos, os autores identificaram uma tendência crescente de utilização de sistemas híbridos entre os trabalhos analisados.

Algarni e Sheldon (2023) também realizaram uma revisão sistemática especificamente voltada à seleção de cursos. O estudo analisou pesquisas publicadas entre 2017 e 2022 e discute desafios associados a esse tipo de recomendação, incluindo a existência de um espaço amplo e dinâmico de alternativas e o problema de *cold-start* para novos usuários.

Silva et al. (2023), em revisão sistemática sobre sistemas de recomendação educacionais voltados ao ensino e à aprendizagem, identificaram a abordagem híbrida como a estratégia predominante entre os estudos selecionados. Os autores também observaram que grande parte das avaliações encontradas estava concentrada na acurácia das recomendações, enquanto poucos trabalhos analisavam sua efetividade pedagógica, apontando a importância de avaliações que considerem outras dimensões dos sistemas educacionais.

Esses estudos demonstram que os sistemas de recomendação educacionais apresentam características próprias do domínio e que a combinação de diferentes fontes de informação tem sido explorada como estratégia para produzir recomendações. Esse cenário se relaciona ao problema investigado neste projeto, no qual estão disponíveis tanto características dos cursos quanto registros históricos de matrículas da EV.G.

Além disso, uma interação com um curso não representa necessariamente uma avaliação explícita de sua qualidade ou relevância. Uma matrícula pode indicar interesse inicial, enquanto situações posteriores, como conclusão, desistência ou reprovação, podem estar associadas a diferentes fatores. Essa distinção reforça a importância de interpretar adequadamente os registros de interação disponíveis ao desenvolver sistemas de recomendação no contexto educacional.

2.6 Avaliação de sistemas de recomendação

A avaliação é uma etapa fundamental no desenvolvimento de sistemas de recomendação, pois permite verificar em que medida os itens apresentados pelo sistema correspondem a itens considerados relevantes para os usuários.

Herlocker et al. (2004) discutem diferentes formas de avaliação de sistemas de filtragem colaborativa e destacam que a escolha das métricas depende da tarefa desempenhada pelo sistema. Avaliações podem ser realizadas de forma *offline*, utilizando dados históricos, ou envolver experimentos com usuários.

Na avaliação *offline*, parte das interações conhecidas pode ser utilizada para construir o modelo, enquanto outra parte é reservada para verificar sua capacidade de recomendar itens relevantes. Entretanto, a maneira como essa separação é realizada influencia os resultados obtidos.

Campos, Díez e Cantador (2014) discutem a importância do tempo na avaliação de sistemas de recomendação e mostram que protocolos que desconsideram a ordem temporal das interações podem produzir condições diferentes daquelas encontradas no uso real do sistema.

Ji et al. (2023) analisam especificamente o problema de vazamento de dados (*data leakage*) na avaliação *offline* de sistemas de recomendação. Quando informações posteriores ao período avaliado acabam sendo utilizadas durante o treinamento ou construção do modelo, o desempenho obtido pode não representar adequadamente a capacidade de recomendação em dados futuros.

Quando o objetivo do sistema é gerar uma lista ordenada de recomendações, podem ser utilizadas métricas voltadas à avaliação de *rankings* Top-K. Cremonesi, Koren e Turrin (2010) discutem a avaliação de algoritmos em tarefas Top-N, nas quais interessa verificar se itens relevantes aparecem entre as primeiras posições recomendadas.

Entre as métricas utilizadas nesse contexto estão Recall@K, Hit Rate@K e NDCG@K.

O Recall@K mede a proporção dos itens relevantes para determinado usuário que aparece entre os K primeiros itens recomendados. Dessa forma, a métrica permite avaliar quanto do conjunto de itens relevantes foi recuperado pelo sistema dentro da lista de recomendações.

O Hit Rate@K verifica se pelo menos um item relevante aparece entre os K primeiros itens recomendados. Quando calculado para vários usuários, permite observar a proporção de casos em que o sistema conseguiu produzir ao menos um acerto dentro da lista.

O NDCG@K (*Normalized Discounted Cumulative Gain*) considera não apenas a presença de itens relevantes na lista, mas também sua posição no *ranking*. Dessa forma, itens relevantes posicionados mais próximos do início da lista recebem maior importância (JÄRVELIN; KEKÄLÄINEN, 2002).

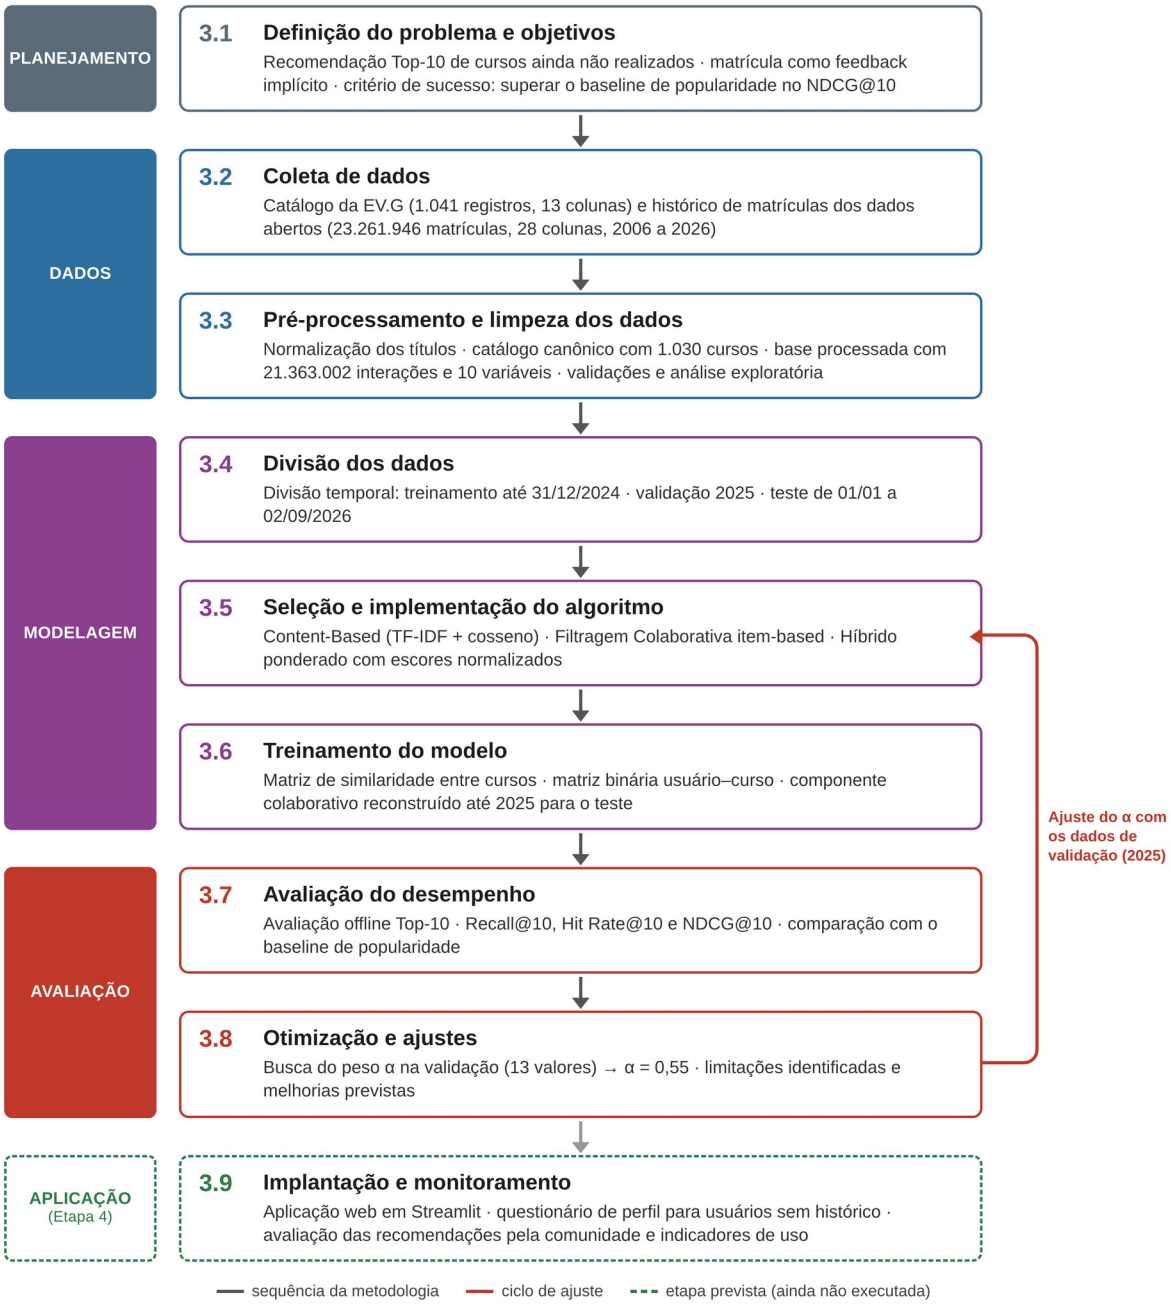
Além da comparação entre diferentes técnicas de recomendação, modelos simples podem funcionar como referências (*baselines*) para avaliar se métodos mais complexos realmente acrescentam capacidade de personalização. Cremonesi, Koren e Turrin (2010) discutem a importância da metodologia utilizada na avaliação de tarefas Top-N e mostram a necessidade de protocolos adequados para comparar algoritmos.

Assim, a literatura apresentada neste capítulo fornece a fundamentação conceitual para os principais elementos envolvidos no problema investigado: representação das características dos cursos, utilização de interações implícitas, filtragem colaborativa, combinação de técnicas em sistemas híbridos e avaliação de listas ordenadas de recomendações. Esses fundamentos também permitem compreender as escolhas técnicas necessárias para o desenvolvimento e a avaliação de um sistema de recomendação aplicado ao catálogo de cursos da EV.G.

3 METODOLOGIA

Nesta seção, é apresentado o desenvolvimento deste trabalho, com a descrição das etapas e das técnicas utilizadas na construção e na avaliação do sistema híbrido de recomendação. O esquema geral da metodologia é apresentado na Figura 1, e cada etapa é detalhada nas subseções seguintes, na mesma ordem do fluxograma.

Figura 1 – Metodologia utilizada no projeto



Fonte: Elaborado pelos autores (2026).

A metodologia foi organizada em nove etapas, agrupadas em cinco fases. No planejamento (seção 3.1), o problema foi formulado como uma tarefa de recomendação Top-10 baseada em *feedback* implícito. Na fase de dados, o catálogo e o histórico de matrículas da EV.G foram coletados (seção 3.2), integrados por meio de um identificador canônico de curso e preparados para a modelagem (seção 3.3). Na modelagem, as interações foram divididas cronologicamente (seção 3.4) e foram implementados e treinados os componentes baseado em conteúdo, colaborativo e híbrido (seções 3.5 e 3.6). Na avaliação, os modelos foram comparados entre si e com um *baseline* de popularidade (seção 3.7), e o peso α do modelo híbrido foi ajustado apenas com os dados de validação de 2025, como indica o ciclo de ajuste da Figura 1 (seção 3.8). O período de 2026 foi reservado ao teste final, sem novos ajustes. A última fase, ainda não executada e prevista para a Etapa 4, corresponde à implantação do sistema para aplicação junto à comunidade e ao seu monitoramento (seção 3.9).

3.1 Definição do Problema e Objetivos

A Escola Virtual de Governo (EV.G), mantida pela Escola Nacional de Administração Pública (Enap), oferece um catálogo de cursos gratuitos que, após a padronização realizada neste trabalho, reúne 1.030 cursos distintos. A quantidade de opções amplia o acesso à capacitação, mas também torna mais difícil, para cada pessoa, identificar quais cursos são mais adequados aos seus interesses e objetivos profissionais. Sem orientação personalizada, a escolha depende de buscas manuais e da navegação por temas, o que pode levar à seleção de conteúdos pouco alinhados às necessidades do usuário.

Neste projeto, o problema foi formulado como uma tarefa de recomendação Top-N. Dado o histórico de matrículas de um usuário até determinada data, o sistema deve ordenar os cursos que ele ainda não realizou e apresentar os dez com maior potencial de interesse. Como a base da EV.G não possui avaliações explícitas dos cursos, a matrícula foi utilizada como *feedback* implícito: a existência de uma relação entre usuário e curso indica interesse, enquanto a ausência de matrícula não é interpretada como avaliação negativa.

A hipótese de trabalho é que a combinação das características dos cursos com os padrões de comportamento dos usuários produz recomendações mais relevantes do que cada abordagem isolada e do que uma recomendação não personalizada, baseada apenas na popularidade dos cursos. Também se espera que o componente baseado em conteúdo permita recomendar cursos sem histórico de matrículas, situação em que a filtragem colaborativa não dispõe de informações (*cold-start* de itens).

Objetivo geral: desenvolver um sistema híbrido de recomendação de cursos voltado ao desenvolvimento profissional, combinando características dos cursos e o histórico de

interações dos usuários para gerar recomendações personalizadas de acordo com seus interesses e perfis.

Objetivos específicos desta etapa:

- Integrar o catálogo de cursos e o histórico de matrículas da EV.G, tratando os dados sem eliminar informações relevantes sobre a trajetória dos usuários;
- Representar as interações como *feedback* implícito binário entre usuário e curso;
- Dividir os dados de forma cronológica, de modo que o desempenho seja medido sobre interações posteriores às utilizadas no treinamento;
- Implementar os modelos baseado em conteúdo, de filtragem colaborativa e híbrido, definindo o peso do híbrido apenas com dados de validação;
- Avaliar os modelos com Recall@10, Hit Rate@10 e NDCG@10 e compará-los a um *baseline* de popularidade;
- Planejar a implantação de uma versão do sistema para aplicação e avaliação junto à comunidade.

O sucesso do sistema foi definido em termos comparativos: o modelo híbrido deveria superar o *baseline* de popularidade no conjunto de teste, sob o mesmo protocolo e com as mesmas métricas, utilizando o NDCG@10 como métrica principal. Esta etapa corresponde a uma prova de conceito (POC) avaliada de forma *offline*, sobre usuários que possuem histórico anterior ao período avaliado. A aplicação com usuários da comunidade é tratada na seção 3.9 como etapa futura.

O Quadro 1 relaciona os objetivos específicos apresentados na seção 1.4 às etapas da metodologia em que foram tratados e aos resultados obtidos nesta etapa do projeto.

Quadro 1 – Relação entre os objetivos do projeto e as etapas da metodologia

Objetivo (seção 1.4)	**Seções**	**Resultado nesta etapa**
Analisar as informações do catálogo e do histórico de matrículas da EV.G	3.2 e 3.3	Bases caracterizadas: 1.041 registros no catálogo e 23.261.946 matrículas no histórico
Preparar os dados para as técnicas de recomendação	3.3 e 3.4	Catálogo canônico com 1.030 cursos, base com 21.363.002 interações e divisão temporal em treinamento, validação e teste
Aplicar a recomendação baseada em conteúdo	3.5.1 e 3.6	Componente TF-IDF com similaridade do cosseno; NDCG@10 de 0,0655 no teste
Aplicar a filtragem colaborativa	3.5.2 e 3.6	Componente *item-based* sobre a matriz binária usuário–curso; NDCG@10 de 0,0761 no teste
Combinar as abordagens em um sistema híbrido	3.5.3 e 3.8.1	Híbrido ponderado com $\alpha = 0{,}55$, escolhido na validação; NDCG@10 de 0,0780 no teste
Avaliar a qualidade e a relevância das recomendações	3.7	Avaliação *offline* com Recall@10, Hit Rate@10 e NDCG@10; híbrido 51,6% acima do *baseline* de popularidade no NDCG@10
Objetivo extensionista: aplicar o sistema junto à comunidade	3.9	Implantação, questionário e indicadores planejados para a Etapa 4

Fonte: Elaborado pelos autores (2026).

3.2 Coleta de Dados

Foram utilizadas duas fontes públicas da Escola Virtual de Governo (EV.G), mantida pela Escola Nacional de Administração Pública (Enap): o catálogo de cursos, no arquivo catalogo.csv, e o histórico de matrículas “EV.G em Números”, no arquivo 20260902_escolavirtual_dadosabertos_matriculas_utf8.csv. O catálogo analisado foi coletado em 2 de setembro de 2026 e contém 1.041 registros e 13 campos. No histórico original, foram identificadas 23.261.946 matrículas, 6.726.766 usuários distintos e 1.214 códigos de curso, em registros de 1º de agosto de 2006 a 2 de setembro de 2026, distribuídos em 28 colunas. As fontes são disponibilizadas no catálogo da EV.G e no portal EV.G em Números (ENAP, [s. d.]a; ENAP, [s. d.]b).

Do catálogo, a representação textual utilizada pelo componente baseado em conteúdo considera nome do curso, eixos temáticos, competências, apresentação, público-alvo e conteúdo programático. Esses campos descrevem os cursos e permitem comparar seus conteúdos. O catálogo também contém identificadores originais e outros atributos, como certificador, conteudista, tipo de oferta, disponibilidade e lançamento, mas nem todos foram incorporados ao texto do modelo.

Na versão final da base processada, foram mantidas 10 colunas: nove campos originais — cod_matricula, dt_matricula, cod_curso, nome_curso, carga_horaria, dt_fim, tematica, sit_matricula e codigo_pessoa — e o identificador id_curso_canonico, criado para integrar o histórico ao catálogo. A base integrada contém 21.363.002 interações, 6.444.712 usuários distintos e registros associados aos 1.030 cursos canônicos. Esses totais descrevem o arquivo preparado após o vínculo ao catálogo, e não a base histórica original.

As fontes são complementares: o catálogo descreve os itens, enquanto o histórico registra as relações entre usuários e cursos. A primeira fonte fornece os atributos usados para representar a similaridade entre cursos; a segunda permite identificar interações observadas e relações entre cursos frequentados por usuários em comum. A combinação viabiliza os componentes baseado em conteúdo e colaborativo utilizados na prova de conceito.

3.3 Pré-processamento e Limpeza dos Dados

A preparação foi realizada em Python, com Pandas, NumPy e DuckDB. O DuckDB foi utilizado para consultar o arquivo de matrículas, de aproximadamente 9 GB, sem a necessidade de carregar todo o histórico na memória. Inicialmente, foram verificadas as dimensões das bases, o período coberto, os identificadores, as situações de matrícula e os valores ausentes. Na revisão final do notebook 01, foram retiradas da base processada

colunas que não seriam utilizadas nas análises ou na modelagem, incluindo informações institucionais com muitos valores ausentes. Os campos mantidos para identificar usuário, curso e situação não apresentaram valores ausentes. No catálogo de 1.030 cursos, os eixos temáticos estavam ausentes em 32 registros e as competências em 628; nome, apresentação, público-alvo e conteúdo programático tinham conteúdo utilizável para todos os cursos. Para a entrada textual do modelo, os campos ausentes foram substituídos por texto vazio antes da concatenação, sem criar informações inexistentes nem excluir os cursos.

A integração não foi feita diretamente entre cod_curso, do histórico, e id_curso, do catálogo, pois esses identificadores possuem formatos diferentes e não formavam uma chave comum confiável. Para criar a correspondência, os títulos dos cursos foram padronizados: o texto foi convertido para minúsculas, os acentos foram removidos por normalização Unicode NFKD, a pontuação foi substituída por espaços e os espaços duplicados foram eliminados. Em seguida, a associação entre o código histórico e o curso do catálogo foi realizada pela igualdade dos títulos normalizados. Os identificadores originais foram preservados para manter a rastreabilidade, enquanto a base integrada passou a utilizar o id_curso_canonico como referência comum.

O catálogo original tinha 1.041 registros. A análise identificou 12 grupos de títulos que coincidiam após a normalização. Em 11 grupos, a comparação dos demais atributos indicou cursos equivalentes, que foram consolidados; assim, o catálogo canônico passou a ter 1.030 cursos. Os atributos distintos dos registros consolidados foram reunidos por ID canônico. O grupo “Inteligência Emocional” exigiu uma decisão específica: as ofertas em português (id_curso original 318) e espanhol (id_curso original 627) têm conteúdos diferentes, embora seus títulos coincidam. Por isso, foram mantidas como itens distintos, com IDs canônicos 601 e 1030, respectivamente. A separação também considerou os códigos históricos: f3bb7055d7 para a oferta em português e 753fb465ec para a oferta em espanhol. O título original foi preservado; o marcador de idioma foi usado apenas na chave de correspondência da oferta em espanhol.

Foram examinados 1.214 códigos históricos: 1.051 tiveram correspondência com um curso do catálogo e 163 não tiveram. Nenhum dos códigos examinados foi associado a mais de um ID canônico. A integração por junção interna (INNER JOIN) manteve as matrículas vinculadas aos códigos mapeados e deixou de fora aquelas sem correspondência confirmada, evitando atribuir interações a cursos cuja identificação não pôde ser estabelecida. Após as etapas de integração e filtragem, a base preparada ficou com 1.898.944 registros a menos que a base original. Com os dados disponíveis, essa redução não pode ser atribuída exclusivamente aos 163 códigos sem correspondência.

As cinco situações de matrícula foram preservadas: Concluida, Desistente, Reprovado, Não Concluído e Trancada. A análise exploratória identificou 1.658.194 pares

usuário–curso com mais de uma interação; 670.668 desses pares apresentavam tanto Concluida quanto Desistente. Na ordenação por data de matrícula, 531.238 tiveram Desistente antes de Concluida e 114.715 apresentaram a ordem inversa. Essa sequência reflete as datas de matrícula dos registros, não necessariamente o momento em que cada situação foi atualizada. Como a desistência não determina, por si só, rejeição ao conteúdo — e há pares em que uma matrícula posterior aparece como concluída —, as situações não foram convertidas em pesos positivos ou negativos. Na matriz binária da filtragem colaborativa, a existência de um par usuário–curso distinto representa *feedback* implícito igual a 1, independentemente da situação; a ausência de registro não é uma avaliação negativa explícita (HU; KOREN; VOLINSKY, 2008).

A verificação não encontrou linhas integralmente duplicadas. Foram identificados 207 valores repetidos em cod_matricula, envolvendo 414 registros, associados a usuários, cursos e datas diferentes. Por esse motivo, cod_matricula foi preservado para rastreabilidade, mas não foi considerado uma chave única global. As interações repetidas do mesmo par usuário–curso também foram mantidas na base preparada. Somente no momento de construir a representação binária de cada período foi aplicado SELECT DISTINCT, de forma que várias matrículas do mesmo usuário no mesmo curso não aumentassem artificialmente o peso dessa interação. A variável dt_inicio apresentou os mesmos valores de dt_matricula nos registros analisados e foi excluída por redundância. Também foram identificados 58 intervalos negativos entre dt_matricula e dt_fim e 81.853 superiores a 365 dias; destes, 81.533 eram exatamente 3.650 dias e estavam concentrados em seis cursos. Esses registros foram preservados na base geral, utilizando-se o intervalo de 0 a 365 dias apenas nas análises específicas de prazo.

A preparação gera uma base de interações integrada e um catálogo canônico para as etapas seguintes. O histórico fornece codigo_pessoa, id_curso_canonico e dt_matricula para representar os pares usuário–curso e ordenar temporalmente as interações; o catálogo fornece os atributos textuais dos itens. Na representação textual inicial, nome do curso e eixos temáticos aparecem repetidos como heurística de ênfase; os demais campos aparecem uma vez. A limpeza, portanto, mantém contexto e rastreabilidade sem transformar status ou ausência de matrícula em avaliações explícitas. A seção seguinte descreve os cortes temporais, e as subseções posteriores detalham a vetorização e os modelos.

3.4 Divisão dos Dados

A partir da base integrada e do catálogo canônico descritos na seção 3.3, foi realizada a divisão temporal das interações, utilizando a data de matrícula (dt_matricula) como referência. Para a modelagem, o histórico foi organizado por usuário (codigo_pessoa) e curso

canônico (id_curso_canonico), preservando a ordem temporal das interações e permitindo separar os dados utilizados na construção dos modelos daqueles destinados à validação e ao teste.

A divisão foi realizada em três períodos: treinamento, abrangendo as interações registradas até 31 de dezembro de 2024; validação, correspondente às interações registradas durante o ano de 2025; e teste, compreendendo o período de 1º de janeiro a 2 de setembro de 2026, conforme a disponibilidade dos dados utilizados no projeto. A Tabela 1 apresenta o volume de interações, usuários e cursos em cada período.

Tabela 1 – Volume de dados em cada período da divisão temporal

Conjunto	Período	Interações	Usuários	Cursos
Treinamento	até 31/12/2024	13.104.833	4.270.327	788
Validação	01/01 a 31/12/2025	4.634.436	1.939.000	975
Teste	01/01 a 02/09/2026	3.623.733	1.626.454	1.029
Total		**21.363.002**		

Fonte: Elaborado pelos autores (2026), com base no notebook 03_modelo_recomendacao.

O conjunto de treinamento foi utilizado na construção inicial dos componentes de recomendação baseada em conteúdo (*Content-Based Filtering*) e de filtragem colaborativa (*Collaborative Filtering*). O conjunto de validação foi empregado para comparar configurações do modelo híbrido e selecionar o parâmetro de combinação dos componentes. Após essa etapa, o conjunto de teste foi reservado para a avaliação temporal final, sem utilização na escolha dos parâmetros.

Para a avaliação personalizada, foram considerados os usuários que possuíam histórico anterior ao período avaliado e apresentaram pelo menos um novo curso durante esse período. Foram avaliados 645.919 usuários na validação de 2025 e 617.448 usuários no teste de 2026. Usuários sem histórico anterior ao período avaliado não foram incluídos nessa avaliação, pois não havia interações anteriores suficientes para construir suas recomendações personalizadas.

A análise temporal identificou cursos presentes nos períodos de validação e teste que não possuíam interações no conjunto de treinamento. Na validação, 19,42% das interações estavam associadas a cursos sem histórico até 2024. No teste, essa proporção foi de 30,88%. Esse cenário caracteriza o problema de *item cold-start* para o componente colaborativo e reforça a relevância de utilizar informações textuais dos cursos na abordagem híbrida.

Para a avaliação final de 2026, o componente colaborativo foi reconstruído com as interações disponíveis até 31 de dezembro de 2025. Dessa forma, o modelo incorporou o histórico de 2025 antes de gerar recomendações para o período de teste, respeitando a ordem temporal das informações. Essa divisão também foi adotada no protocolo de avaliação

descrito na seção 3.7, garantindo correspondência entre os períodos utilizados na construção dos modelos e aqueles empregados na mensuração de seu desempenho.

3.5 Seleção e Implementação do Algoritmo

Foram implementados três componentes de recomendação: baseado em conteúdo, filtragem colaborativa *item-based* e um modelo híbrido que combina as pontuações dos dois primeiros. A escolha dessas abordagens considerou a disponibilidade de informações textuais sobre os cursos e o histórico de matrículas dos usuários, bem como a possibilidade de combinar sinais complementares para gerar recomendações personalizadas.

3.5.1 Recomendação baseada em conteúdo (*Content-Based Filtering*)

O componente baseado em conteúdo utiliza as características descritivas dos cursos para identificar itens semelhantes aos presentes no histórico de cada usuário. Conforme descrito na seção 3.2, foram considerados os campos nome do curso, eixos temáticos, competências, apresentação, público-alvo e conteúdo programático.

Os campos textuais foram combinados em uma representação por curso. Para dar maior ênfase a determinados atributos, o nome do curso e os eixos temáticos foram repetidos no texto utilizado pelo modelo (o nome três vezes e os eixos temáticos duas vezes), enquanto os demais campos foram incluídos uma vez. Os textos foram então transformados em vetores numéricos por meio da técnica TF-IDF (*Term Frequency–Inverse Document Frequency*), utilizando unigramas e bigramas. Essa técnica atribui pesos aos termos considerando sua frequência nos documentos e sua relevância no conjunto analisado (SALTON; BUCKLEY, 1988). A vetorização foi realizada com a biblioteca scikit-learn (PEDREGOSA et al., 2011), desconsiderando termos presentes em menos de dois cursos ou em mais de 95% deles, o que resultou em uma matriz de 1.030 cursos por 14.526 termos.

A partir dos vetores TF-IDF, foi calculada a similaridade do cosseno entre os cursos. Para cada usuário, a pontuação de um curso candidato foi obtida pela média das similaridades entre esse candidato e os cursos presentes em seu histórico anterior ao período de avaliação. Os cursos já presentes no histórico do usuário foram excluídos da lista de recomendação.

Essa abordagem permite gerar recomendações com base nas características dos próprios cursos, inclusive para itens sem interações no período utilizado na construção do componente colaborativo, desde que estejam representados no catálogo e possuam atributos textuais utilizáveis.

3.5.2 Filtragem colaborativa *item-based* (*Item-Based Collaborative Filtering*)

O componente colaborativo utiliza os padrões de interação entre usuários e cursos para identificar relações comportamentais entre os itens (SARWAR et al., 2001). Para isso, foi construída uma matriz binária usuário–curso a partir dos identificadores codigo_pessoa e id_curso_canonico, respeitando os limites temporais definidos na seção 3.4.

Cada par distinto usuário–curso foi representado por um valor binário igual a 1, indicando a existência de uma interação. Embora as matrículas repetidas tenham sido preservadas na base preparada para fins de rastreabilidade e análise, elas foram consolidadas na matriz de modelagem, de modo que múltiplas matrículas do mesmo usuário em um mesmo curso não aumentassem artificialmente o peso dessa interação.

As cinco situações de matrícula foram preservadas na base de origem, mas não receberam pesos positivos ou negativos no cálculo do *feedback* implícito. Essa decisão considera que a base não possui avaliações explícitas dos cursos e que os status de matrícula, isoladamente, não permitem inferir de forma confiável a satisfação ou a rejeição do usuário. Assim, a existência de um par usuário–curso foi utilizada como sinal de interação, e a ausência de registro não foi interpretada como uma avaliação negativa explícita.

A similaridade do cosseno foi calculada entre as colunas da matriz usuário–curso, correspondentes aos cursos. Dessa forma, cursos com padrões semelhantes de interação entre usuários podem receber pontuações de similaridade mais elevadas.

Para gerar recomendações, as relações entre os cursos presentes no histórico do usuário foram agregadas para calcular as pontuações dos itens candidatos. Os cursos já conhecidos pelo usuário foram excluídos da lista final. Como esse componente depende de interações anteriores para aprender relações entre itens, cursos sem histórico no período de treinamento não possuem relações colaborativas aprendidas a partir daquele conjunto de dados.

3.5.3 Modelo híbrido

O modelo híbrido combina as pontuações produzidas pelo componente baseado em conteúdo e pelo componente colaborativo, buscando aproveitar a complementaridade entre as duas abordagens. Enquanto o primeiro utiliza as características textuais dos cursos, o segundo explora padrões de comportamento identificados no histórico de matrículas.

Antes da combinação, as pontuações dos dois componentes foram normalizadas individualmente por usuário, dividindo-se os escores de cada componente pelo maior escore obtido para o respectivo usuário. Essa etapa permite combinar os escores em uma escala comparável, reduzindo a influência de diferenças de magnitude entre as pontuações originais. A normalização é distinta da binarização das matrículas, descrita na seção anterior, que ocorre durante a construção da matriz de interações.

A pontuação híbrida foi calculada por meio de uma combinação linear ponderada (BURKE, 2002), conforme a Equação 1:

$$S_{\text{híbrido}}(u, i) = \alpha \cdot S_{\text{conteúdo,norm}}(u, i) + (1 - \alpha) \cdot S_{\text{colaborativo,norm}}(u, i) \quad (1)$$

em que u representa o usuário, i representa o curso candidato, $S_{\text{conteúdo,norm}}$ corresponde à pontuação normalizada do componente baseado em conteúdo, $S_{\text{colaborativo,norm}}$ corresponde à pontuação normalizada do componente colaborativo e α controla a contribuição relativa do primeiro componente.

Os cursos foram ordenados de acordo com a pontuação híbrida, desconsiderando aqueles já presentes no histórico do usuário. A seleção do parâmetro α foi realizada exclusivamente com base no conjunto de validação de 2025. O procedimento de busca e a justificativa para o valor selecionado são apresentados na seção 3.8.1.

3.6 Treinamento do Modelo

O treinamento foi estruturado de acordo com a natureza de cada componente. No modelo baseado em conteúdo, os atributos textuais dos cursos foram combinados e transformados em vetores TF-IDF, a partir dos quais foi calculada a matriz de similaridade do cosseno entre os itens. Essa representação permite calcular pontuações personalizadas a partir dos cursos presentes no histórico de cada usuário.

No componente colaborativo, as interações anteriores ao período de avaliação foram organizadas em uma matriz binária usuário–curso. Para sua construção, foram consideradas as relações distintas entre codigo_pessoa e id_curso_canonico, evitando que matrículas repetidas do mesmo usuário no mesmo curso aumentassem artificialmente a intensidade da interação. A partir dessa matriz, foi calculada a similaridade entre os cursos, utilizada posteriormente para pontuar os itens candidatos com base no histórico individual dos usuários.

A existência de uma matrícula foi adotada como sinal de *feedback* implícito, independentemente da situação registrada. Essa escolha não significa que toda matrícula resulte em conclusão ou satisfação, mas que, na configuração da prova de conceito, a matrícula é utilizada como evidência de interação comportamental. A decisão está alinhada ao tratamento dos dados descrito na seção 3.3 e à definição do protocolo de avaliação apresentado na seção 3.7.1.

Durante a validação, os escores dos componentes foram combinados com diferentes valores do parâmetro α. O NDCG@10 foi adotado como critério principal para a escolha da configuração híbrida, pois considera tanto a presença de cursos relevantes nas recomendações quanto suas posições na lista ordenada. O procedimento de busca e os resultados para os diferentes valores avaliados são detalhados na seção 3.8.1.

Com base na validação de 2025, foi selecionado o valor α = 0,55, correspondente a 55% de contribuição do componente baseado em conteúdo e 45% do componente colaborativo. Esse parâmetro foi mantido fixo durante a avaliação no conjunto de teste de 2026, sem novos ajustes.

Para a avaliação final, o componente colaborativo foi reconstruído com as interações disponíveis até 31 de dezembro de 2025, ampliando o histórico utilizado na geração das recomendações para o teste. Assim, o conjunto de teste permaneceu reservado à mensuração final do desempenho da configuração selecionada, mantendo a separação temporal entre treinamento, validação e teste.

3.7 Avaliação do Desempenho

A avaliação do desempenho foi realizada de forma *offline*, a partir do histórico de matrículas da EV.G, comparando as recomendações geradas por cada modelo com os cursos efetivamente realizados pelos usuários em um período posterior ao utilizado na construção dos modelos. Foram avaliados quatro modelos: o *baseline* de popularidade, o *Content-Based*, a Filtragem Colaborativa *item-based* e o modelo Híbrido. Todos foram submetidos ao mesmo protocolo, com os mesmos usuários, os mesmos cursos-alvo e as mesmas métricas.

3.7.1 Protocolo de avaliação

A avaliação seguiu a divisão temporal descrita na seção 3.4: os modelos são construídos com as interações até 31/12/2024, a validação utiliza as interações de 2025 e o teste final utiliza as interações de 1º de janeiro a 2 de setembro de 2026. Para o teste, o componente colaborativo foi reconstruído com os dados até 31/12/2025 (seção 3.6). Essa separação evita que informações posteriores ao período avaliado sejam utilizadas na construção dos modelos, o que poderia superestimar o desempenho (JI et al., 2023).

Como a base da EV.G não possui avaliações explícitas dos cursos, cada matrícula foi tratada como um sinal binário de interação, independentemente de sua situação. Em cada período avaliado, foram considerados os usuários que possuíam histórico anterior ao período e que realizaram pelo menos um curso novo, isto é, um curso ainda ausente em seu histórico. Resultaram 645.919 usuários na validação e 617.448 no teste. Usuários que aparecem pela primeira vez no período avaliado (*cold-start* de usuário) não possuem histórico para a construção de um perfil individual e, por isso, não participam desta avaliação personalizada.

Para cada usuário, cada modelo gerou uma lista Top-10 entre os cursos do catálogo atual (1.030 cursos canônicos), excluindo os cursos já presentes em seu histórico. Essa lista foi comparada aos cursos relevantes do usuário, definidos como os cursos distintos com os quais ele interagiu no período avaliado e que ainda não constavam em seu histórico.

Repetições de cursos já realizados não foram consideradas alvos de recomendação. O procedimento segue a lógica de avaliação de tarefas Top-N (CREMONESI; KOREN; TURRIN, 2010).

3.7.2 Métricas

O desempenho foi medido por três métricas, todas com K = 10. Cada métrica foi calculada para cada usuário e, em seguida, foi obtida a média entre os usuários avaliados:

- **Recall@10:** proporção dos cursos relevantes do usuário que aparecem entre as dez recomendações;
- **Hit Rate@10:** proporção de usuários para os quais pelo menos um curso relevante aparece entre as dez recomendações;
- **NDCG@10:** considera, além da presença dos cursos relevantes, a posição em que aparecem na lista, atribuindo maior peso aos acertos nas primeiras posições (JÄRVELIN; KEKÄLÄINEN, 2002).

O NDCG@10 foi adotado como métrica principal, por considerar a posição dos acertos no *ranking*, e foi o critério utilizado na escolha do parâmetro α do modelo híbrido (seção 3.8).

3.7.3 *Baseline* de popularidade

Foi construído um *baseline* não personalizado de popularidade, que serve como referência mínima para verificar se a personalização contribui para a qualidade das recomendações. Para cada usuário, o *baseline* recomenda os dez cursos com maior número de usuários distintos no período de treinamento, excluindo os cursos já presentes em seu histórico. A popularidade foi calculada exclusivamente com dados anteriores ao período avaliado: até 31/12/2024 na validação e até 31/12/2025 no teste. O *baseline* foi avaliado com os mesmos usuários, cursos-alvo e métricas dos demais modelos.

3.7.4 Resultados

As Tabelas 2 e 3 apresentam os resultados na validação (2025) e no teste (2026). O ganho de NDCG@10 sobre o *baseline* foi calculado com os valores sem arredondamento.

Tabela 2 – Desempenho dos modelos na validação (2025; 645.919 usuários)

Modelo	**Recall@10**	**Hit Rate@10**	**NDCG@10**	**Ganho de NDCG@10 sobre o *baseline***
Popularidade (*baseline*)	0,0913	0,1746	0,0570	—
Content-Based	0,0956	0,1772	0,0682	+19,6%
Filtragem Colaborativa	0,1098	0,2002	0,0715	+25,5%
Híbrido (α = 0,55)	**0,1153**	**0,2049**	**0,0791**	**+38,8%**

Fonte: Elaborado pelos autores (2026), com base no notebook 03_modelo_recomendacao (seções 7.7 e 7.8).

Tabela 3 – Desempenho dos modelos no teste (2026; 617.448 usuários)

Modelo	**Recall@10**	**Hit Rate@10**	**NDCG@10**	**Ganho de NDCG@10 sobre o *baseline***
Popularidade (*baseline*)	0,0830	0,1481	0,0515	—
Content-Based	0,0957	0,1649	0,0655	+27,3%
Filtragem Colaborativa	0,1139	0,1893	0,0761	+47,9%
Híbrido (α = 0,55)	**0,1151**	**0,1914**	**0,0780**	**+51,6%**

Fonte: Elaborado pelos autores (2026), com base no notebook 03_modelo_recomendacao (seções 7.7 e 7.8).

O modelo híbrido apresentou os maiores valores observados nas três métricas, tanto na validação quanto no teste. Em relação ao NDCG@10, superou o *baseline* de popularidade em 38,8% na validação (0,0791 contra 0,0570) e em 51,6% no teste (0,0780 contra 0,0515). A Filtragem Colaborativa também superou o *baseline* e o *Content-Based* isolado nos dois períodos. O modelo híbrido apresentou resultados adicionais em relação à Filtragem Colaborativa, embora a diferença tenha sido menor no teste, no qual o NDCG@10 foi de 0,0780 para o híbrido e de 0,0761 para a Filtragem Colaborativa.

O *baseline* de popularidade apresentou resultados relevantes, mesmo sem personalização: 17,5% dos usuários receberam pelo menos um curso relevante entre as dez recomendações na validação, enquanto no teste esse percentual foi de 14,8%. Na validação, o *Content-Based* isolado apresentou Hit Rate@10 próximo ao do *baseline* (0,1772 contra 0,1746), mas obteve NDCG@10 superior (0,0682 contra 0,0570), indicando melhor desempenho nessa métrica, que também considera a posição dos cursos relevantes no *ranking*.

Os resultados devem ser interpretados considerando as limitações do protocolo de avaliação, especialmente a ausência de testes estatísticos para verificar a significância das diferenças observadas entre os modelos.

3.7.5 Limitações da avaliação

As comparações foram feitas sobre valores médios das métricas, sem aplicação de testes estatísticos. Por isso, os resultados indicam que o híbrido obteve os melhores valores observados, sem permitir concluir que sua diferença em relação à Filtragem Colaborativa seja estatisticamente significativa, em especial no teste. Além disso, o universo de candidatos é o catálogo atual, e os usuários sem histórico anterior ao período avaliado não entram na avaliação personalizada. Por fim, o *baseline* utiliza a popularidade acumulada durante todo o período de treinamento; referências mais exigentes, como a popularidade recente ou por segmento de usuários, poderiam ser exploradas em trabalhos futuros.

3.8 Otimização e Ajustes

3.8.1 Escolha do peso α do modelo híbrido

O modelo híbrido combina as pontuações do *Content-Based* e da Filtragem Colaborativa por meio de uma média ponderada (BURKE, 2002), em que α é o peso do componente baseado em conteúdo, conforme a Equação 1 (seção 3.5.3).

As pontuações de cada componente são normalizadas por usuário antes da combinação (seção 3.5.3). Para evitar a escolha arbitrária do peso, α foi selecionado no conjunto de validação (2025), com base no NDCG@10, em três rodadas de busca: (i) valores de 0,00 a 1,00, em passos de 0,25, em que 0,00 corresponde ao componente colaborativo isolado e 1,00 ao *Content-Based* isolado; (ii) refinamento de 0,25 a 0,50, em passos de 0,05; e (iii) refinamento de 0,50 a 0,75, também em passos de 0,05. A Tabela 4 reúne os 13 valores avaliados.

Tabela 4 – Desempenho do modelo híbrido na validação (2025) para diferentes valores de α

α	Pesos (conteúdo / colaborativo)	Recall@10	Hit Rate@10	NDCG@10
0,00	0% / 100%	0,1098	0,2002	0,0715
0,25	25% / 75%	0,1177	0,2092	0,0761
0,30	30% / 70%	0,1142	0,2033	0,0759
0,35	35% / 65%	0,1149	0,2044	0,0764
0,40	40% / 60%	0,1159	0,2057	0,0769
0,45	45% / 55%	0,1162	0,2063	0,0774
0,50	50% / 50%	0,1161	0,2061	0,0778
0,55	**55% / 45%**	**0,1153**	**0,2049**	**0,0791**
0,60	60% / 40%	0,1146	0,2040	0,0786
0,65	65% / 35%	0,1129	0,2015	0,0778
0,70	70% / 30%	0,1104	0,1981	0,0765
0,75	75% / 25%	0,1082	0,1948	0,0754
1,00	100% / 0%	0,0956	0,1772	0,0682

Fonte: Elaborado pelos autores (2026), com base no notebook 03_modelo_recomendacao (seções 6.2 a 6.4). Em destaque, o valor selecionado.

O maior valor de NDCG@10 na validação foi obtido com α = 0,55 (0,0791), correspondente a 55% da pontuação do *Content-Based* e 45% da pontuação da Filtragem Colaborativa. Para valores de α superiores a 0,55, o NDCG@10 apresentou redução. Nessa configuração, o modelo obteve Recall@10 de 0,1153 e Hit Rate@10 de 0,2049. Outros valores de α apresentaram resultados superiores nessas duas métricas, como α = 0,25, com Recall@10 de 0,1177 e Hit Rate@10 de 0,2092. Ainda assim, α = 0,55 foi selecionado por apresentar o maior NDCG@10, métrica principal adotada na avaliação por considerar também a posição dos cursos relevantes no *ranking*.

A configuração α = 0,55 foi definida com base na validação de 2025. O conjunto de teste de 2026 foi reservado para a avaliação final do modelo selecionado, sem utilização na escolha desse parâmetro.

3.8.2 Limitações identificadas e melhorias previstas

O principal ajuste da POC foi a escolha do peso α do modelo híbrido, descrita na seção 3.8.1. Os demais parâmetros, como os pesos dos campos textuais e a configuração do TF-IDF, foram mantidos na configuração inicial. A análise dos resultados e das decisões adotadas ao longo das etapas permitiu identificar as limitações reunidas no Quadro 2, que complementa a seção 3.7.5 e indica a melhoria prevista para cada uma.

Quadro 2 – Limitações identificadas e melhorias previstas

Limitação	**Efeito sobre os resultados**	**Melhoria prevista**
Catálogo atual como universo de candidatos	A disponibilidade histórica dos cursos não foi reconstruída; a variável data_lancamento apresentou datas posteriores a 2026 e não foi utilizada	Incorporar versões temporais (*snapshots*) do catálogo, caso se tornem disponíveis
Cold-start de usuários	63,66% dos usuários de 2025 e 57,80% dos de 2026 não tinham histórico anterior e ficaram fora da avaliação personalizada	Questionário de perfil na aplicação (seção 3.9)
Feedback implícito binário	A situação da matrícula não recebe peso; a conclusão não equivale a uma avaliação de satisfação	Testar ponderações controladas, avaliadas no conjunto de validação
Representação textual heurística	Nome repetido três vezes e eixos duas vezes; sem remoção de *stopwords* em português; o TF-IDF não reconhece sinônimos	Representações separadas por campo com pesos validados; LSA (TruncatedSVD) ou *embeddings* de linguagem
Correspondência entre as bases	163 dos 1.214 códigos históricos sem correspondência com o catálogo; a base preparada tem 1.898.944 registros a menos que a original	Investigar os códigos sem correspondência e avaliar o uso do histórico de cursos que não constam mais no catálogo
Comparação sem testes estatísticos	A diferença entre híbrido e colaborativo no teste é pequena (NDCG@10 de 0,0780 contra 0,0761)	Testes pareados por usuário, como *bootstrap* ou Wilcoxon
Baseline único	A popularidade considera todo o período de treinamento	Baselines de popularidade recente e por segmento de usuários

Fonte: Elaborado pelos autores (2026).

Também se observou que o *baseline* de popularidade foi o modelo com maior queda entre a validação e o teste, o que aumentou a vantagem relativa do híbrido em 2026. Entre os possíveis fatores estão a maior participação de interações com cursos sem histórico no treinamento (30,88% no teste, contra 19,42% na validação) e a reconstrução do componente

colaborativo com os dados de 2025. Essas hipóteses não foram testadas; uma avaliação separada para cursos com e sem histórico permitiria verificá-las.

As melhorias foram priorizadas segundo seu impacto na aplicação extensionista. O tratamento do *cold-start* de usuários é a primeira prioridade, pois as pessoas da comunidade não possuem histórico na base. Em seguida, os testes estatísticos e os *baselines* mais exigentes fortalecem a interpretação dos resultados. As mudanças de representação textual ficam como evolução posterior, a serem avaliadas pelo mesmo protocolo temporal.

3.9 Implantação e Monitoramento

A implantação ainda não foi executada e está prevista para a Etapa 4, na forma de uma aplicação web desenvolvida em Python com a biblioteca Streamlit e acessada por um link público. Esta seção descreve como o sistema será disponibilizado à comunidade, como serão geradas as recomendações para pessoas sem histórico na EV.G e quais indicadores serão acompanhados.

Versão implantada. A aplicação utilizará uma versão leve do recomendador. Em vez de processar os mais de 21 milhões de interações a cada acesso, serão carregados apenas arquivos pré-calculados: o catálogo canônico, a representação TF-IDF dos cursos, as matrizes de similaridade entre cursos (1.030 × 1.030) dos componentes de conteúdo e colaborativo e o *ranking* de popularidade. Nenhum dado individual do histórico de matrículas precisa ser publicado na aplicação.

Fluxo de uso. A pessoa responde a um questionário de múltipla escolha com ramificações: as perguntas seguintes variam conforme o objetivo informado, como buscar o primeiro emprego ou crescer na carreira atual. Com as respostas, o sistema monta um perfil inicial e apresenta uma lista de cursos recomendados, com nome, carga horária e link de acesso na EV.G. Por fim, a pessoa avalia se as recomendações fazem sentido para ela.

Tratamento do *cold-start*. Como os participantes não possuem histórico na base, o perfil será construído a partir das respostas. A proposta em discussão pelo grupo combina três recursos:

1. Interesses, temas e competências escolhidos no questionário são convertidos em texto e representados no mesmo espaço TF-IDF dos cursos, o que permite calcular a similaridade de conteúdo entre o perfil e o catálogo;
2. Se a pessoa indicar cursos da EV.G que já realizou ou que lhe interessam, esses cursos funcionam como histórico inicial, e o modelo híbrido com $\alpha = 0{,}55$ pode ser aplicado como na POC;
3. A popularidade dentro dos temas escolhidos complementa a lista quando o perfil tiver poucas informações.

Avaliação pela comunidade. Para cada curso recomendado, o participante indicará se a recomendação é útil. Ao final, avaliará a relevância e a utilidade da lista em uma escala de 1 a 5. As respostas serão registradas de forma anônima, sem nome, e-mail ou outro dado que identifique a pessoa, e analisadas na Etapa 4. Antes de iniciar o questionário, o participante será informado sobre a finalidade acadêmica da coleta e dará seu consentimento, em conformidade com a Lei Geral de Proteção de Dados Pessoais (BRASIL, 2018).

Monitoramento. Durante a aplicação, serão acompanhados os indicadores apresentados no Quadro 3.

Quadro 3 – Indicadores de monitoramento da aplicação

Indicador	**O que mede**
Questionários concluídos / acessos	Adesão e facilidade de uso do questionário
Proporção de cursos avaliados como úteis	Relevância percebida, comparável ao Hit Rate e ao Recall da avaliação *offline*
Nota média de relevância e utilidade	Satisfação geral com a lista
Cursos distintos recomendados	Cobertura do catálogo e concentração em cursos populares
Erros e tempo de resposta	Estabilidade da aplicação

Fonte: Elaborado pelos autores (2026).

Atualização do modelo. Como a EV.G publica periodicamente seus dados abertos, o modelo poderá ser retreinado com novas versões do histórico e do catálogo. Antes de substituir a versão em uso, cada novo treinamento será avaliado pelo mesmo protocolo temporal e comparado ao *baseline* de popularidade. Os arquivos de cada versão serão mantidos no repositório do grupo, para permitir rastrear e reproduzir os resultados.

4 REFERÊNCIAS

ADOMAVICIUS, G.; TUZHILIN, A. Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions. **IEEE Transactions on Knowledge and Data Engineering**, v. 17, n. 6, p. 734-749, 2005. DOI: 10.1109/TKDE.2005.99.

AGGARWAL, C. C. **Recommender systems**: the textbook. Cham: Springer, 2016.

ALGARNI, S.; SHELDON, F. Systematic review of recommendation systems for course selection. **Machine Learning and Knowledge Extraction**, v. 5, n. 2, p. 560-596, 2023. DOI: 10.3390/make5020033.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). **Diário Oficial da União**: seção 1, Brasília, DF, 15 ago. 2018.

BURKE, R. Hybrid recommender systems: survey and experiments. **User Modeling and User-Adapted Interaction**, v. 12, n. 4, p. 331-370, 2002. DOI: 10.1023/A:1021240730564.

CAMPOS, P. G.; DÍEZ, F.; CANTADOR, I. Time-aware recommender systems: a comprehensive survey and analysis of existing evaluation protocols. **User Modeling and User-Adapted Interaction**, v. 24, n. 1-2, p. 67-119, 2014. DOI: 10.1007/s11257-012-9136-x.

ÇANO, E.; MORISIO, M. Hybrid recommender systems: a systematic literature review. **Intelligent Data Analysis**, v. 21, n. 6, p. 1487-1524, 2017. DOI: 10.3233/IDA-163209.

CREMONESI, P.; KOREN, Y.; TURRIN, R. Performance of recommender algorithms on top-N recommendation tasks. In: ACM CONFERENCE ON RECOMMENDER SYSTEMS, 4., 2010, Barcelona. **Proceedings** [...]. New York: ACM, 2010. p. 39-46. DOI: 10.1145/1864708.1864721.

ENAP – ESCOLA NACIONAL DE ADMINISTRAÇÃO PÚBLICA. **Catálogo de cursos da Escola Virtual de Governo**. Brasília, DF: Enap, [s. d.]a. Disponível em: https://www.escolavirtual.gov.br/catalogo. Acesso em: 2 set. 2026.

ENAP – ESCOLA NACIONAL DE ADMINISTRAÇÃO PÚBLICA. **EV.G em Números**: dados abertos. Brasília, DF: Enap, [s. d.]b. Disponível em: https://emnumeros.escolavirtual.gov.br/dados-abertos/. Acesso em: 2 set. 2026.

GURUGE, D. B.; KADEL, R.; HALDER, S. J. The state of the art in methodologies of course recommender systems: a review of recent research. **Data**, v. 6, n. 2, art. 18, 2021. DOI: 10.3390/data6020018.

HERLOCKER, J. L. et al. Evaluating collaborative filtering recommender systems. **ACM Transactions on Information Systems**, v. 22, n. 1, p. 5-53, 2004. DOI: 10.1145/963770.963772.

HU, Y.; KOREN, Y.; VOLINSKY, C. Collaborative filtering for implicit feedback datasets. In: IEEE INTERNATIONAL CONFERENCE ON DATA MINING, 8., 2008, Pisa. **Proceedings** [...]. Los Alamitos: IEEE, 2008. p. 263-272. DOI: 10.1109/ICDM.2008.22.

JÄRVELIN, K.; KEKÄLÄINEN, J. Cumulated gain-based evaluation of IR techniques. **ACM Transactions on Information Systems**, v. 20, n. 4, p. 422-446, 2002. DOI: 10.1145/582415.582418.

JI, Y. et al. A critical study on data leakage in recommender system offline evaluation. **ACM Transactions on Information Systems**, v. 41, n. 3, art. 75, 2023. DOI: 10.1145/3569930.

KHANAL, S. S. et al. A systematic review: machine learning based recommendation systems for e-learning. **Education and Information Technologies**, v. 25, n. 4, p. 2635-2664, 2020. DOI: 10.1007/s10639-019-10063-9.

LINDEN, G.; SMITH, B.; YORK, J. Amazon.com recommendations: item-to-item collaborative filtering. **IEEE Internet Computing**, v. 7, n. 1, p. 76-80, 2003. DOI: 10.1109/MIC.2003.1167344.

LOPS, P.; GEMMIS, M. de; SEMERARO, G. Content-based recommender systems: state of the art and trends. In: RICCI, F. et al. (ed.). **Recommender systems handbook**. Boston: Springer, 2011. p. 73-105.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011.

RICCI, F.; ROKACH, L.; SHAPIRA, B. (ed.). **Recommender systems handbook**. 3. ed. New York: Springer, 2022.

SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. **Information Processing & Management**, v. 24, n. 5, p. 513-523, 1988. DOI: 10.1016/0306-4573(88)90021-0.

SARWAR, B. et al. Item-based collaborative filtering recommendation algorithms. In: INTERNATIONAL CONFERENCE ON WORLD WIDE WEB, 10., 2001, Hong Kong. **Proceedings** [...]. New York: ACM, 2001. p. 285-295. DOI: 10.1145/371920.372071.

SCHEIN, A. I. et al. Methods and metrics for cold-start recommendations. In: ANNUAL INTERNATIONAL ACM SIGIR CONFERENCE ON RESEARCH AND DEVELOPMENT IN INFORMATION RETRIEVAL, 25., 2002, Tampere. **Proceedings** [...]. New York: ACM, 2002. p. 253-260. DOI: 10.1145/564376.564421.

SILVA, F. L. da et al. A systematic literature review on educational recommender systems for teaching and learning: research trends, limitations and opportunities. **Education and Information Technologies**, v. 28, n. 3, p. 3289-3328, 2023. DOI: 10.1007/s10639-022-11341-9.

URDANETA-PONTE, M. C.; MENDEZ-ZORRILLA, A.; OLEAGORDIA-RUIZ, I. Recommendation systems for education: systematic review. **Electronics**, v. 10, n. 14, art. 1611, 2021. DOI: 10.3390/electronics10141611.