



SISTEMA HÍBRIDO DE RECOMENDAÇÃO DE CURSOS PARA DESENVOLVIMENTO PROFISSIONAL

ALLANA RAYSSA VIEIRA DE OLIVEIRA - 10397812
ERIKA CRISTINA ALVES BENESI GOMES - 10732522
NICOLE FERNANDES MOREIRA - 10747302
TAWANY NASCIMENTO SANTOS - 10746742

UNIVERSIDADE PRESBITERIANA MACKENZIE

São Paulo, 2026

SUMÁRIO

1 INTRODUÇÃO	3
1.1 Contexto do trabalho	3
1.2 Motivação	4
1.3 Justificativa	5
1.4 Objetivo geral, objetivos específicos da pesquisa e objetivo extensionista	6
Objetivo geral	6
Objetivos específicos	6
Objetivo extensionista	6
2 REFERENCIAL TEÓRICO	7
2.1 Sistemas de recomendação	7
2.2 Recomendação baseada em conteúdo	9
2.3 Filtragem colaborativa	10
2.4 Sistemas híbridos de recomendação	11
2.5 Sistemas de recomendação na educação	12
2.6 Avaliação de sistemas de recomendação	13
3 REFERÊNCIAS	15

1 INTRODUÇÃO

1.1 Contexto do trabalho

Atualmente, a qualificação profissional não acontece apenas no início da carreira. Com as mudanças no mercado de trabalho e o uso cada vez maior de tecnologia nas atividades profissionais, as pessoas precisam atualizar seus conhecimentos com frequência. Isso aumentou a procura por cursos online, que permitem estudar sem restrição de horário e de local. O Censo da Educação Superior de 2024, divulgado pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP), mostra esse crescimento: as matrículas em cursos a distância já superaram as dos cursos presenciais, e a modalidade está presente em 3.387 municípios brasileiros, o equivalente a 61% do total. Além da educação formal, também cresceu a oferta de cursos livres e de curta duração, muitos deles gratuitos.

O aumento da oferta facilitou o acesso à capacitação, mas criou outra dificuldade: a de escolher o que estudar. Em catálogos com centenas ou milhares de cursos, o usuário precisa decidir sozinho qual curso fazer, em que ordem e com qual profundidade. Na maioria das plataformas, essa decisão é apoiada apenas por busca por palavra-chave, filtros por área e listas dos cursos mais acessados. Esses recursos funcionam bem quando a pessoa já sabe o nome daquilo que procura, mas ajudam pouco quem ainda não conhece as opções da área em que pretende atuar. Como consequência, a busca pode se tornar demorada e levar à escolha de conteúdos que não correspondem ao objetivo profissional ou ao nível de conhecimento que o usuário já possui.

Os sistemas de recomendação foram desenvolvidos para lidar com esse tipo de problema. Eles analisam informações sobre os itens disponíveis e sobre o comportamento dos usuários para sugerir aquilo que tem maior chance de ser relevante para cada pessoa. Já são utilizados em lojas virtuais e em serviços de streaming e vêm sendo aplicados também na área educacional, para indicar cursos, disciplinas e materiais de estudo. As abordagens mais comuns são a filtragem baseada em conteúdo (content-based), que sugere itens parecidos com aqueles pelos quais o usuário já demonstrou interesse; a filtragem colaborativa (collaborative filtering), que utiliza o comportamento de usuários com histórico

semelhante; e a abordagem híbrida, que combina as duas para reduzir as limitações de cada uma.

No Brasil, a Escola Virtual de Governo (EV.G), mantida pela Escola Nacional de Administração Pública (ENAP), é um exemplo desse cenário. A plataforma reúne em um catálogo único mais de mil cursos gratuitos e abertos a qualquer pessoa, organizados em áreas como dados e informação, gestão de pessoas, tecnologia da informação, políticas públicas e ética e cidadania. Seu portal de dados abertos registra mais de 23 milhões de matrículas e cerca de 6,7 milhões de usuários. A quantidade de cursos disponíveis mostra que a dificuldade de escolha também está presente nessa plataforma e o volume de matrículas registradas indica que existem dados suficientes para identificar padrões de uso e apoiar a recomendação.

Diante desse cenário, este projeto propõe o desenvolvimento de um sistema híbrido de recomendação de cursos voltado ao desenvolvimento profissional, que leve em consideração o perfil, os interesses e o histórico de interações dos usuários. Serão utilizados o catálogo de cursos e a base de matrículas da EV.G, com a finalidade de ajudar o usuário a encontrar cursos mais adequados aos seus objetivos sem depender apenas de buscas manuais.

Os materiais relacionados ao desenvolvimento do projeto, incluindo os conjuntos de dados utilizados, códigos e demais artefatos produzidos ao longo das etapas, serão organizados no repositório do projeto no GitHub, disponível em: <https://github.com/Allana691/Projeto-aplicado-III>

1.2 Motivação

A escolha do tema está relacionada à crescente oferta de cursos de capacitação e à necessidade de facilitar a escolha de oportunidades de desenvolvimento profissional que sejam adequadas aos diferentes perfis e objetivos dos usuários. Embora existam diversas plataformas que disponibilizam cursos gratuitos e pagos, a grande quantidade de opções pode dificultar a identificação de conteúdos realmente relevantes para cada pessoa.

Nesse contexto, o projeto busca contribuir para tornar o processo de busca por capacitação mais direcionado, considerando que diferentes usuários possuem interesses, conhecimentos prévios e objetivos profissionais distintos.

A utilização de dados para apoiar esse processo pode reduzir a necessidade de buscas manuais e auxiliar o usuário na identificação de cursos potencialmente mais relevantes para sua trajetória profissional.

A escolha da Escola Virtual de Governo (EV.G) como fonte de dados também contribui para a relevância social do projeto, uma vez que a plataforma disponibiliza cursos gratuitos de diferentes áreas de conhecimento, ampliando o acesso à capacitação profissional.

1.3 Justificativa

O desenvolvimento de um sistema de recomendação de cursos para capacitação profissional é justificado pela crescente quantidade de opções disponíveis e pela dificuldade dos usuários em identificar quais conteúdos são mais adequados aos seus interesses, conhecimentos e objetivos. Embora a oferta de cursos online facilite o acesso à capacitação, a grande quantidade de alternativas pode tornar o processo de escolha mais demorado e pouco direcionado. Nesse contexto, a utilização de sistemas de recomendação pode auxiliar os usuários na identificação de cursos potencialmente mais relevantes para seu desenvolvimento profissional, reduzindo a dependência de buscas manuais e de listas gerais de conteúdos.

A utilização de uma abordagem híbrida é relevante por permitir a combinação de diferentes informações para gerar recomendações personalizadas. A recomendação baseada em conteúdo pode considerar as características dos cursos e os interesses dos usuários, enquanto a filtragem colaborativa pode utilizar o histórico de interações para identificar padrões de comportamento entre usuários com preferências semelhantes. A combinação dessas abordagens possibilita a geração de recomendações mais completas e adequadas aos diferentes perfis, além de representar uma aplicação prática de técnicas de Ciência de Dados.

A proposta também apresenta viabilidade devido à disponibilidade de dados reais e brasileiros da Escola Virtual de Governo (EV.G). As bases analisadas possuem informações suficientes sobre os cursos e um histórico significativo de matrículas, possibilitando o desenvolvimento e a avaliação do sistema com base em dados reais. Além de sua aplicação técnica, o projeto possui relevância prática e social, pois a disponibilização do sistema para testes pela comunidade permitirá avaliar a utilidade das recomendações e contribuir

para o aprimoramento da solução, auxiliando pessoas na busca por oportunidades de capacitação e desenvolvimento profissional.

1.4 Objetivo geral, objetivos específicos da pesquisa e objetivo extensionista

Objetivo geral

Desenvolver um sistema híbrido de recomendação de cursos voltado ao desenvolvimento profissional, combinando características dos cursos e o histórico de interações dos usuários para gerar recomendações personalizadas de acordo com seus interesses e perfis.

Objetivos específicos

- Analisar as informações disponíveis no catálogo de cursos e no histórico de matrículas da Escola Virtual de Governo (EV.G), identificando os dados relevantes para o desenvolvimento do sistema de recomendação;
- Preparar os dados selecionados para possibilitar sua utilização nas técnicas de recomendação;
- Aplicar técnicas de recomendação baseada em conteúdo, considerando as características dos cursos e os interesses dos usuários;
- Aplicar técnicas de filtragem colaborativa, utilizando o histórico de interações para identificar padrões entre usuários e cursos;
- Combinar as abordagens baseada em conteúdo e colaborativa para desenvolver um sistema híbrido de recomendação;
- Avaliar a qualidade e a relevância das recomendações geradas pelo sistema por meio de métodos adequados de avaliação.

Objetivo extensionista

Aplicar o sistema de recomendação junto à comunidade, utilizando informações padronizadas sobre interesses, conhecimentos e objetivos profissionais dos participantes para gerar recomendações personalizadas de cursos da Escola Virtual de Governo (EV.G) e avaliar, por meio de questionário estruturado, a percepção dos usuários quanto à relevância e à utilidade das recomendações apresentadas. A aplicação busca contribuir para facilitar o

acesso a oportunidades de capacitação e desenvolvimento profissional, atendendo às necessidades relacionadas ao ODS 4 – Educação de Qualidade e ao ODS 8 – Trabalho Decente e Crescimento Econômico.

A relação com o ODS 4 ocorre pela utilização de um sistema de recomendação para auxiliar os participantes na identificação de oportunidades gratuitas de aprendizagem mais adequadas aos seus interesses, conhecimentos e objetivos, contribuindo para tornar a busca por capacitação mais direcionada. Em relação ao ODS 8, o projeto busca apoiar o desenvolvimento profissional dos participantes ao recomendar cursos que contribuam para a aquisição e o aprimoramento de conhecimentos e competências relacionados aos seus objetivos profissionais.

2 REFERENCIAL TEÓRICO

Este capítulo apresenta os conceitos que fundamentam o desenvolvimento de sistemas de recomendação e sua aplicação no contexto educacional. Considerando que o projeto propõe um sistema híbrido de recomendação de cursos, são discutidas inicialmente as características gerais dos sistemas de recomendação e, em seguida, as abordagens baseada em conteúdo e colaborativa, bem como sua combinação em sistemas híbridos.

Também são apresentados estudos sobre a aplicação dessas técnicas na educação e, especificamente, na recomendação de cursos. Por fim, são discutidas formas de avaliação de sistemas de recomendação, incluindo métricas adequadas para sistemas que produzem listas ordenadas de itens. Esses conceitos fornecem a fundamentação necessária para compreender as técnicas utilizadas no desenvolvimento do projeto.

2.1 Sistemas de recomendação

Com o crescimento da quantidade de informações, produtos e serviços disponíveis em ambientes digitais, tornou-se mais difícil para os usuários localizar itens relevantes entre um grande número de alternativas. Os sistemas de recomendação surgiram como uma forma de reduzir essa sobrecarga de informação por meio da identificação de itens potencialmente relevantes para cada usuário (ADOMAVICIUS; TUZHILIN, 2005).

Ricci, Rokach e Shapira (2022) definem os sistemas de recomendação como ferramentas e técnicas de software destinadas a fornecer sugestões de itens que possam ser úteis a determinado usuário. Nesse contexto, o termo “item” pode representar diferentes elementos, como produtos, filmes, notícias, músicas ou cursos, dependendo do domínio em que o sistema é aplicado.

Segundo Adomavicius e Tuzhilin (2005), uma das funções de um sistema de recomendação consiste em estimar a utilidade de itens para usuários e, a partir dessa estimativa, selecionar aqueles considerados mais relevantes. Em determinadas aplicações, o objetivo não é prever uma avaliação numérica específica, mas produzir uma lista ordenada dos itens considerados mais adequados. Esse tipo de problema é conhecido como recomendação Top-N (AGGARWAL, 2016).

Existem diferentes abordagens para produzir recomendações. Entre elas estão os métodos baseados em conteúdo, que utilizam características dos itens; os métodos colaborativos, que exploram padrões existentes nas interações dos usuários; os métodos baseados em conhecimento; e os sistemas híbridos, que combinam duas ou mais estratégias (BURKE, 2002; RICCI; ROKACH; SHAPIRA, 2022).

Outro aspecto importante diz respeito à forma como as preferências dos usuários são obtidas. No feedback explícito, o usuário fornece diretamente uma avaliação sobre determinado item, por exemplo, atribuindo-lhe uma nota. No feedback implícito, por outro lado, as preferências são inferidas a partir de comportamentos observáveis, como compras, cliques ou outras formas de interação (HU; KOREN; VOLINSKY, 2008).

Hu, Koren e Volinsky (2008) destacam que dados implícitos apresentam características diferentes das avaliações explícitas. A ausência de uma interação não representa necessariamente falta de interesse, assim como uma interação não permite concluir diretamente o grau de satisfação do usuário. Ainda assim, esse tipo de informação possibilita explorar padrões de comportamento quando avaliações explícitas não estão disponíveis.

No contexto educacional, registros de matrícula podem constituir uma forma de interação implícita entre usuários e cursos. Essa característica é particularmente relevante para bases como a da Escola Virtual de Governo (EV.G), utilizada neste projeto, na qual o histórico disponível registra as matrículas e suas respectivas situações, mas não apresenta avaliações individuais dos cursos pelos usuários.

2.2 Recomendação baseada em conteúdo

A recomendação baseada em conteúdo (*content-based recommendation*) utiliza as características dos itens para identificar elementos semelhantes àqueles pelos quais um usuário já demonstrou interesse. Para isso, os itens precisam ser representados por seus atributos e o histórico de interação pode ser utilizado para construir um perfil de preferências do usuário (LOPS; GEMMIS; SEMERARO, 2011).

Quando os itens possuem informações textuais, esses textos precisam ser transformados em uma representação numérica para que possam ser comparados computacionalmente. Uma técnica tradicional para essa finalidade é o TF-IDF (*Term Frequency – Inverse Document Frequency*), que representa documentos por meio de vetores nos quais os termos recebem pesos de acordo com sua frequência no documento e sua ocorrência no conjunto de documentos (SALTON; BUCKLEY, 1988).

A lógica do TF-IDF permite reduzir a importância de termos muito frequentes no conjunto de documentos e atribuir maior peso àqueles mais representativos de determinado texto. Dessa forma, descrições textuais podem ser convertidas em vetores capazes de representar parte de suas características.

Após a representação vetorial dos itens, medidas de similaridade podem ser utilizadas para comparar esses vetores. Entre elas está a similaridade do cosseno, que considera o ângulo formado entre dois vetores. Quanto maior a similaridade, maior tende a ser a proximidade entre suas representações (LOPS; GEMMIS; SEMERARO, 2011).

Uma das vantagens da recomendação baseada em conteúdo é a possibilidade de recomendar itens utilizando suas próprias características, mesmo quando esses itens ainda possuem poucas ou nenhuma interação. Além disso, as características responsáveis pela recomendação podem contribuir para sua explicabilidade (LOPS; GEMMIS; SEMERARO, 2011).

Essa abordagem também apresenta limitações. A qualidade das recomendações depende das informações disponíveis para descrever os itens, e o sistema pode apresentar superespecialização, recomendando itens excessivamente semelhantes àqueles já conhecidos pelo usuário. Também existe o problema relacionado a usuários novos, para os quais ainda não há histórico suficiente para representar suas preferências (LOPS; GEMMIS; SEMERARO, 2011).

No domínio de cursos, características como título, descrição, conteúdo programático, público-alvo e área temática podem fornecer informações úteis para a representação dos itens. O catálogo da EV.G contém diferentes atributos textuais desse tipo, permitindo que os cursos sejam caracterizados a partir de seus conteúdos.

2.3 Filtragem colaborativa

A filtragem colaborativa (*collaborative filtering*) utiliza as interações registradas entre usuários e itens para identificar padrões de preferência. A ideia fundamental é que informações sobre comportamentos anteriores podem ser utilizadas para estimar quais itens poderão ser relevantes para determinado usuário (HERLOCKER et al., 2004).

Aggarwal (2016) apresenta diferentes formas de filtragem colaborativa, incluindo métodos baseados em vizinhança e métodos baseados em modelos. Nos métodos de vizinhança, a similaridade pode ser calculada entre usuários ou entre itens. Na abordagem baseada em usuários, são identificados usuários com padrões de interação semelhantes. Na abordagem baseada em itens (*item-based*), por outro lado, são identificados itens que apresentam padrões semelhantes de interação.

Sarwar et al. (2001) estudaram algoritmos de filtragem colaborativa baseados em itens, nos quais as relações entre os itens são calculadas a partir dos usuários que interagiram com eles. Essa abordagem permite utilizar as relações identificadas entre itens para produzir recomendações.

Linden, Smith e York (2003) apresentam um exemplo conhecido da aplicação dessa estratégia em grande escala na Amazon, utilizando filtragem colaborativa item a item para lidar com grandes quantidades de usuários e produtos. A abordagem baseada em itens pode ser especialmente relevante em cenários nos quais o número de usuários é significativamente superior ao número de itens disponíveis.

Quando as interações correspondem a feedback implícito, a relação entre usuário e item pode ser representada, por exemplo, pela ocorrência ou não de determinada interação. A similaridade entre itens pode então ser estimada a partir dos padrões de interação observados (AGGARWAL, 2016).

Apesar de amplamente utilizada, a filtragem colaborativa apresenta limitações. Uma delas é a esparsidade, decorrente do fato de que cada usuário normalmente interage apenas com uma pequena parcela dos itens disponíveis,

deixando grande parte da matriz usuário-item sem interações (ADOMAVICIUS; TUZHILIN, 2005).

Outra limitação é o problema de partida a frio (*cold-start*), que pode ocorrer quando um usuário ainda não possui histórico suficiente ou quando um item novo ainda não recebeu interações (SCHEIN et al., 2002). Esse problema também é discutido no contexto específico de sistemas de recomendação de cursos por Algarni e Sheldon (2023), que identificam o *cold-start* entre os desafios encontrados nesse domínio.

2.4 Sistemas híbridos de recomendação

Os sistemas híbridos combinam duas ou mais técnicas de recomendação com o objetivo de aproveitar características complementares e reduzir limitações associadas a abordagens individuais (BURKE, 2002).

Uma combinação recorrente envolve métodos baseados em conteúdo e filtragem colaborativa. Enquanto a abordagem baseada em conteúdo utiliza as características dos itens e pode lidar melhor com itens que ainda possuem poucas interações, a filtragem colaborativa utiliza padrões coletivos de comportamento e pode identificar relações que não seriam evidentes apenas pela análise das características dos itens (BURKE, 2002; ADOMAVICIUS; TUZHILIN, 2005).

Burke (2002) apresenta diferentes estratégias para a construção de sistemas híbridos, entre elas as formas ponderada (*weighted*), alternada (*switching*), mista (*mixed*), combinação de atributos (*feature combination*), cascata (*cascade*), aumento de atributos (*feature augmentation*) e meta-nível (*meta-level*).

Na estratégia ponderada, por exemplo, diferentes componentes podem produzir pontuações que posteriormente são combinadas por meio de pesos. Quando as pontuações são produzidas em escalas diferentes, sua combinação pode exigir procedimentos de normalização para permitir uma comparação adequada.

Çano e Morisio (2017), em uma revisão sistemática sobre sistemas híbridos de recomendação, analisam diferentes formas de hibridização e destacam a utilização recorrente da combinação entre filtragem colaborativa e métodos baseados em conteúdo. A literatura relaciona o uso de abordagens híbridas à possibilidade de compensar limitações presentes quando cada técnica é empregada isoladamente.

No contexto específico da recomendação de cursos, Guruge, Kadel e Halder (2021) analisaram pesquisas publicadas entre 2016 e 2020 e identificaram diferentes metodologias, incluindo técnicas colaborativas, baseadas em conteúdo, baseadas em conhecimento, mineração de dados e sistemas híbridos. Os autores observaram crescimento da utilização de abordagens híbridas nas pesquisas analisadas.

A combinação entre conteúdo e comportamento apresenta relação direta com problemas como o da partida a frio. Um componente baseado em conteúdo pode utilizar as características de um curso mesmo quando ele possui poucas interações, enquanto um componente colaborativo pode explorar padrões existentes no histórico dos usuários. Essas propriedades tornam os sistemas híbridos particularmente relevantes para ambientes que possuem simultaneamente informações sobre os itens e registros de interação.

2.5 Sistemas de recomendação na educação

Na área educacional, sistemas de recomendação têm sido estudados como ferramentas para apoiar a seleção de diferentes tipos de recursos, como materiais de aprendizagem, objetos educacionais, cursos e outros conteúdos relacionados ao processo de ensino e aprendizagem.

Urdaneta-Ponte, Mendez-Zorrilla e Oleagordia-Ruiz (2021) realizaram uma revisão sistemática sobre sistemas de recomendação aplicados à educação. O estudo analisou 98 trabalhos selecionados a partir de pesquisas em bases como IEEE, ACM, Scopus e Web of Science e identificou como principais abordagens a filtragem colaborativa, a recomendação baseada em conteúdo e os sistemas híbridos. Os autores também observaram uma tendência de utilização de técnicas de aprendizado de máquina nos estudos mais recentes analisados.

Khanal et al. (2020), em uma revisão sistemática sobre sistemas de recomendação baseados em aprendizado de máquina para *e-learning*, também apresentam diferentes estratégias utilizadas nesse domínio, incluindo abordagens colaborativas, baseadas em conteúdo, híbridas e baseadas em conhecimento.

Especificamente em relação à recomendação de cursos, Guruge, Kadel e Halder (2021) destacam que a diversidade de opções pode dificultar a seleção de cursos compatíveis com os conhecimentos e objetivos dos usuários. Ao revisar metodologias empregadas em sistemas de recomendação de cursos, os

autores identificaram uma tendência crescente de utilização de sistemas híbridos entre os trabalhos analisados.

Algarni e Sheldon (2023) também realizaram uma revisão sistemática especificamente voltada à seleção de cursos. O estudo analisou pesquisas publicadas entre 2017 e 2022 e discute desafios associados a esse tipo de recomendação, incluindo a existência de um espaço amplo e dinâmico de alternativas e o problema de *cold-start* para novos usuários.

Silva et al. (2023), em revisão sistemática sobre sistemas de recomendação educacionais voltados ao ensino e à aprendizagem, identificaram a abordagem híbrida como a estratégia predominante entre os estudos selecionados. Os autores também observaram que grande parte das avaliações encontradas estava concentrada na acurácia das recomendações, enquanto poucos trabalhos analisavam sua efetividade pedagógica, apontando a importância de avaliações que considerem outras dimensões dos sistemas educacionais.

Esses estudos demonstram que os sistemas de recomendação educacionais apresentam características próprias do domínio e que a combinação de diferentes fontes de informação tem sido explorada como estratégia para produzir recomendações. Esse cenário se relaciona ao problema investigado neste projeto, no qual estão disponíveis tanto características dos cursos quanto registros históricos de matrículas da EV.G.

Além disso, uma interação com um curso não representa necessariamente uma avaliação explícita de sua qualidade ou relevância. Uma matrícula pode indicar interesse inicial, enquanto situações posteriores, como conclusão, desistência ou reprovação, podem estar associadas a diferentes fatores. Essa distinção reforça a importância de interpretar adequadamente os registros de interação disponíveis ao desenvolver sistemas de recomendação no contexto educacional.

2.6 Avaliação de sistemas de recomendação

A avaliação é uma etapa fundamental no desenvolvimento de sistemas de recomendação, pois permite verificar em que medida os itens apresentados pelo sistema correspondem a itens considerados relevantes para os usuários.

Herlocker et al. (2004) discutem diferentes formas de avaliação de sistemas de filtragem colaborativa e destacam que a escolha das métricas depende da tarefa desempenhada pelo sistema. Avaliações podem ser

realizadas de forma *offline*, utilizando dados históricos, ou envolver experimentos com usuários.

Na avaliação *offline*, parte das interações conhecidas pode ser utilizada para construir o modelo, enquanto outra parte é reservada para verificar sua capacidade de recomendar itens relevantes. Entretanto, a maneira como essa separação é realizada influencia os resultados obtidos.

Campos, Díez e Cantador (2014) discutem a importância do tempo na avaliação de sistemas de recomendação e mostram que protocolos que desconsideram a ordem temporal das interações podem produzir condições diferentes daquelas encontradas no uso real do sistema.

Ji et al. (2023) analisam especificamente o problema de vazamento de dados (*data leakage*) na avaliação *offline* de sistemas de recomendação. Quando informações posteriores ao período avaliado acabam sendo utilizadas durante o treinamento ou construção do modelo, o desempenho obtido pode não representar adequadamente a capacidade de recomendação em dados futuros.

Quando o objetivo do sistema é gerar uma lista ordenada de recomendações, podem ser utilizadas métricas voltadas à avaliação de rankings Top-K. Cremonesi, Koren e Turrin (2010) discutem a avaliação de algoritmos em tarefas Top-N, nas quais interessa verificar se itens relevantes aparecem entre as primeiras posições recomendadas.

Entre as métricas utilizadas nesse contexto estão Recall@K, Hit Rate@K e NDCG@K.

O Recall@K mede a proporção dos itens relevantes para determinado usuário que aparece entre os K primeiros itens recomendados. Dessa forma, a métrica permite avaliar quanto do conjunto de itens relevantes foi recuperado pelo sistema dentro da lista de recomendações.

O Hit Rate@K verifica se pelo menos um item relevante aparece entre os K primeiros itens recomendados. Quando calculado para vários usuários, permite observar a proporção de casos em que o sistema conseguiu produzir ao menos um acerto dentro da lista.

O NDCG@K (*Normalized Discounted Cumulative Gain*) considera não apenas a presença de itens relevantes na lista, mas também sua posição no ranking. Dessa forma, itens relevantes posicionados mais próximos do início da lista recebem maior importância (JÄRVELIN; KEKÄLÄINEN, 2002).

Além da comparação entre diferentes técnicas de recomendação, modelos simples podem funcionar como referências (*baselines*) para avaliar se

métodos mais complexos realmente acrescentam capacidade de personalização. Cremonesi, Koren e Turrin (2010) discutem a importância da metodologia utilizada na avaliação de tarefas Top-N e mostram a necessidade de protocolos adequados para comparar algoritmos.

Assim, a literatura apresentada neste capítulo fornece a fundamentação conceitual para os principais elementos envolvidos no problema investigado: representação das características dos cursos, utilização de interações implícitas, filtragem colaborativa, combinação de técnicas em sistemas híbridos e avaliação de listas ordenadas de recomendações. Esses fundamentos também permitem compreender as escolhas técnicas necessárias para o desenvolvimento e a avaliação de um sistema de recomendação aplicado ao catálogo de cursos da EV.G.

3 REFERÊNCIAS

- ADOMAVICIUS, G.; TUZHILIN, A. Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engineering*, v. 17, n. 6, p. 734-749, 2005. DOI: 10.1109/TKDE.2005.99.
- AGGARWAL, C. C. *Recommender systems: the textbook*. Cham: Springer, 2016.
- ALGARNI, S.; SHELDON, F. Systematic review of recommendation systems for course selection. *Machine Learning and Knowledge Extraction*, v. 5, n. 2, p. 560-596, 2023. DOI: 10.3390/make5020033.
- BURKE, R. Hybrid recommender systems: survey and experiments. *User Modeling and User-Adapted Interaction*, v. 12, n. 4, p. 331-370, 2002. DOI: 10.1023/A:1021240730564.
- CAMPOS, P. G.; DÍEZ, F.; CANTADOR, I. Time-aware recommender systems: a comprehensive survey and analysis of existing evaluation protocols. *User Modeling and User-Adapted Interaction*, v. 24, n. 1-2, p. 67-119, 2014. DOI: 10.1007/s11257-012-9136-x.
- ÇANO, E.; MORISIO, M. Hybrid recommender systems: a systematic literature review. *Intelligent Data Analysis*, v. 21, n. 6, p. 1487-1524, 2017. DOI: 10.3233/IDA-163209.
- CREMONESI, P.; KOREN, Y.; TURRIN, R. Performance of recommender algorithms on top-N recommendation tasks. In: *ACM CONFERENCE ON RECOMMENDER*

SYSTEMS, 4., 2010, Barcelona. *Proceedings [...]*. New York: ACM, 2010. p. 39-46. DOI: 10.1145/1864708.1864721.

GURUGE, D. B.; KADEL, R.; HALDER, S. J. The state of the art in methodologies of course recommender systems: a review of recent research. *Data*, v. 6, n. 2, art. 18, 2021. DOI: 10.3390/data6020018.

HERLOCKER, J. L. et al. Evaluating collaborative filtering recommender systems. *ACM Transactions on Information Systems*, v. 22, n. 1, p. 5-53, 2004. DOI: 10.1145/963770.963772.

HU, Y.; KOREN, Y.; VOLINSKY, C. Collaborative filtering for implicit feedback datasets. In: IEEE INTERNATIONAL CONFERENCE ON DATA MINING, 8., 2008, Pisa. *Proceedings [...]*. Los Alamitos: IEEE, 2008. p. 263-272. DOI: 10.1109/ICDM.2008.22.

JÄRVELIN, K.; KEKÄLÄINEN, J. Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, v. 20, n. 4, p. 422-446, 2002. DOI: 10.1145/582415.582418.

JL, Y. et al. A critical study on data leakage in recommender system offline evaluation. *ACM Transactions on Information Systems*, v. 41, n. 3, art. 75, 2023. DOI: 10.1145/3569930.

KHANAL, S. S. et al. A systematic review: machine learning based recommendation systems for e-learning. *Education and Information Technologies*, v. 25, n. 4, p. 2635-2664, 2020. DOI: 10.1007/s10639-019-10063-9.

LINDEN, G.; SMITH, B.; YORK, J. Amazon.com recommendations: item-to-item collaborative filtering. *IEEE Internet Computing*, v. 7, n. 1, p. 76-80, 2003. DOI: 10.1109/MIC.2003.1167344.

LOPS, P.; GEMMIS, M. de; SEMERARO, G. Content-based recommender systems: state of the art and trends. In: RICCI, F. et al. (ed.). *Recommender systems handbook*. Boston: Springer, 2011. p. 73-105.

RICCI, F.; ROKACH, L.; SHAPIRA, B. (ed.). *Recommender systems handbook*. 3. ed. New York: Springer, 2022.

SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, v. 24, n. 5, p. 513-523, 1988. DOI: 10.1016/0306-4573(88)90021-0.

SARWAR, B. et al. Item-based collaborative filtering recommendation algorithms. In: INTERNATIONAL CONFERENCE ON WORLD WIDE WEB, 10., 2001, Hong Kong. *Proceedings [...]*. New York: ACM, 2001. p. 285-295. DOI: 10.1145/371920.372071.

SCHEIN, A. I. et al. Methods and metrics for cold-start recommendations. In: ANNUAL INTERNATIONAL ACM SIGIR CONFERENCE ON RESEARCH AND DEVELOPMENT IN INFORMATION RETRIEVAL, 25., 2002, Tampere. *Proceedings [...]*. New York: ACM, 2002. p. 253-260. DOI: 10.1145/564376.564421.

SILVA, F. L. da et al. A systematic literature review on educational recommender systems for teaching and learning: research trends, limitations and opportunities. *Education and Information Technologies*, v. 28, n. 3, p. 3289-3328, 2023. DOI: 10.1007/s10639-022-11341-9.

URDANETA-PONTE, M. C.; MENDEZ-ZORRILLA, A.; OLEAGORDIA-RUIZ, I. Recommendation systems for education: systematic review. *Electronics*, v. 10, n. 14, art. 1611, 2021. DOI: 10.3390/electronics10141611.